BinN Studies シリーズ

マルコフ連鎖から大規模言語モデルへ

現代行動理論の基礎と応用

羽藤英二　編著
小川大智　須賀理帆　古橋郁一　松永隆宏　今村啓太　著

```
## パラメータ値の最適化
res <- optim(b0, fn, method="BFGS", hessian=TRUE,control=list(fnscale=-1))

## パラメータ推定値，ヘッセ行列
b <- res$par
hhh <- res$hessian

## t 値の計算
tval <- b/sqrt(-diag(solve(hhh)))

## 初期尤度
L0 <- fn(b0)
## 最終尤度
LL <- res$value

##### 結果の出力 #####
## 初期尤度
print(L0)
## 最終尤度
print(LL)
## ρ^2 値
print(1-LL/L0)
## 修正済み ρ^2 値
print(1-(LL-length(b))/L0)
## パラメータ推定値
print(b)
## t 値
print(tval)
```

目 次

第 1 章　はじめに 5

参考文献 7

第 2 章　機械学習の基礎 11

2.1　機械学習の基礎 11

2.1.1　機械学習の歴史 11

2.1.2　機械学習の基本設定 12

2.1.3　損失関数と最適化 14

2.1.4　確率的勾配降下法 (SGD) 15

2.1.5　誤差逆伝播法 17

2.1.6　ニューラルネットワークの基本構造 18

2.1.7　正則化と汎化 19

2.1.8　CNN 21

2.1.9　RNN 22

2.1.10　Transformer 23

参考文献 25

2.2　強化学習 27

2.2.1　強化学習の歴史 27

2.2.2　マルコフ決定過程 28

2.2.3　多腕バンディット問題 30

2.2.4　動的計画法 31

2.2.5　価値ベース手法：Q 学習, Deep-Q 学習 32

2.2.6　方策勾配法：Actor-Critic, PPO 34

2.2.7　発展的話題 35

2.2.8　まとめ 37

参考文献 37

2.3　拡散モデルと生成モデル 39

2.3.1　生成モデルの考え方 39

2.3.2 EM アルゴリズム 41
2.3.3 VAE 43
2.3.4 拡散モデル 44
2.3.5 連続時間拡散モデル 46
2.3.6 自己回帰モデルと LLM 47
2.3.7 世界モデル 49

第 1 章

はじめに

人口減少が進んでいた地方都市を襲った巨大災害直後の破壊の風景の中に立ったとき，何かできたことはなかったか，どうすればよかったのかと思わずにはいられなかった．今，都市と交通を学ぶことにどのような意味があるのだろうか．あるいは激変する社会の中で今私たちに何ができるだろうか．おそらくそれは，道路や鉄道，駅前広場や沿道空間の形を単に学ぶことではない．現実の空間とネットワークの上で，人びとが LLM が得意とする言語のやりとりを超えて「空間」をどのように認知し，選択し，互いに影響し合い，その集積として流れ = 交通が生まれ，外部不経済としての混雑や滞留，さらには回遊，分断，格差がどのように発生しているのかを捉え直すことである．そして，よりよい理解に基づく行為の反復の果てに，都市空間そのものの価値と構造が歴史的な過程を通じていかにその地理的関係が変容していくのか，徹底的に理解することなくして，いかなる政策も計画も設計もサービスも，威勢のいい掛け声をかけたところで何も変わらないのではないだろうか．

行動モデル，ネットワーク配分，最適化，機械学習という本書の四つの柱は，この過程を，個人の意思決定から社会的な空間変容まで貫いて理解するための基礎理論である．本書の目的は，それらを別々の計算技術として紹介することではない．研究の作業と思考の往復のなかで私たちが考えてきたように，人びとの選択の連鎖がネットワーク現象を生成し，その現象を変えようとしてなされる現実の都市設計や交通計画の行為が，再び人びとの行動そのものを変え，その反復が都市自体を更新していく．この連関を，私たち自身が経験してきた都市設計，交通計画，そしてそれらを下支えする基礎理論の構築と実証の蓄積を踏まえながら，ひとつの連続した知の体系として描き直すことに本書の狙いがある．

その出発点のひとつが，**?**] によって基礎づけられた離散選択理論である．2000 年のノーベル経済学賞へと結実したこの理論は，人はなぜこの経路を選び，この交通手段を選び，この場所へ向かうのかという問いに対し，効用と確率的選択という考え方によって，個人の意思決定を政策や空間設計に応答する構造として厳密に記述する道を開いた．こうして離散選択モデルは世界中の交通計画に利用され，インフラ整備の基礎理論として定着するに至った．ここで重要なのは，ネットワーク上の行動が単なる心理学的記述にとどまらず，制度変更や空間条件の変化に対して地理的分布として応答する対象となったことである．この視点があったからこそ，交通行動は社会基盤計画の中心に置かれ，公共交通計画，都市計画，駅まち設計，自動車交通制御に共通する理論的基礎が築かれたといえよう．

しかし，個人の選択を理解するだけでは都市は見えない．選択はネットワーク上で重なり合い，混雑，所要時間，遅延，容量制約，乗換え負荷，滞在時間といった現象へと変換されるからである．

マルコフ過程はこうした行動の連鎖を記述する上で最も基礎的な理論であり，最短経路探索，利用者均衡，確率的配分，動的配分と結びつくことでネットワーク上の行動記述という点で大きな力を発揮することとなった．**?**] と**?**] は，この問題をネットワーク上の均衡として定式化する道を拓いた．さらに，物流や配車，公共交通運用に目を向ければ，単なる経路選択にとどまらず，誰がどの需要をいつどの順序で担うかという組合せ設計が前景化し，**?**] 以来の VRP，さらには列生成，双対問題，**?**] に代表される分解法が，現実の大規模問題に対抗するための基礎となってきた．こうしたアルゴリズムの実装は，線形代数に基礎づけられた行列計算によって支えられている．そして近年では，ChatGPT の登場によって，その実装や試行錯誤が以前よりはるかに身近なものとなったといってよいだろう．

さらに，現実の交通と都市は，唯一の均衡点に収束する静的な系としてではなく，学習し適応する動的な系として再定義されるべきであろう．制度が変われば人は行動を変え，情報が変われば期待も変わる．**? ?**] による人口ゲームと進化動学は，この適応の反復そのものを理論化した点で，従来の均衡配分を決定的に拡張する契機となった．さらにいえば，交通政策とは，ある時点の均衡をずらす一度きりの操作ではない．人びとの模倣，学習，反応，慣性の上に新たな安定状態を形成していく過程への介入なのである．近年の Matsunaga and Hato（2026）は，この系譜を受け継ぎつつ，部分可制御性の下で平均場的インセンティブと逆オークションを結びつけ，都市鉄道混雑制御を設計問題として捉え直している．そこでは，限られた予算，私的情報，日々の適応，平均場的結合が，ひとつの閉ループ系として統合されつつある．

同時に，日々の経路変更や需要変動を実証的に捉えるには，個票レベルの長期観測と，それを扱いうる学習理論が必要になる．Ogawa and Hato（2026）は，1 か月規模の個人 GPS 軌跡から日々の経路変更を捉え，Temporal Boltzmann Machine と Graph Attention Network，さらに correlated equilibrium の制約を組み合わせることで，共有情報に対する異質で相関した適応反応を表現しようとしている．ここで重要なのは，深層学習を単なる高精度予測器として用いるのではなく，信念更新や相関した適応の代理構造をもつ実証モデルとして位置づけている点である．学習は理論を置き換えるのではなく，理論が十分に捉えきれてこなかった観測の厚みに踏み込むための手段となる．

この文脈の上に，Transformer や大規模言語モデルを起点とする近年の AI の急速な発展が重なる．**?**] 以降，系列の長距離依存を捉える注意機構，表現学習，生成モデルは，活動スケジュール，経路系列，都市記述，需要変動の理解に新しい可能性を開いた．さらに，物理法則や保存則を学習に埋め込む PINN は，**?**] 以降，データ駆動型学習と数理モデルの橋渡しとして注目されている．しかし，ここで立ち止まらなければならない．都市と交通の本質は，言語の中だけに存在するのではない．人は文を読んで移動するのではなく，身体をもち，制約を受け，他者と干渉し，空間の抵抗や誘因の中で行動する．そして，その行動は実際にネットワーク負荷を変え，土地利用を変え，拠点の価値を変え，都市そのものを作り替えてしまう．私たちは世界各地の現実の都市や駅を設計し，交通計画を評価し，都市計画に取り組んできた．

その経験から考えるとき，既存の理論はなお，本質的な都市の問題を記述するには十分ではないのではないか．たしかに LLM は強力である．しかしなお最終理論としての弱点がないわけではない．都市と交通に必要なのは，LLM の基盤となる「言語」を超えて，現実の「空間」に作用する物理的な選択，相互作用，制約，学習，設計を統合する理論である．人の行動がネットワーク上で

どのように干渉し合い，その反復がどのように都市の形を変え，さらにその変わった都市が次の行動をどのように規定するのか．この循環を捉えるには，効用理論，均衡理論，進化動学，最適化，深層学習，さらには物理制約までを横断しなければならない．都市を「語れる」知能ではなく，都市を「説明し，予測し，設計できる」知能をめぐって世界中の研究者たちが訥々と自分たちの課題と向き合い続けている．

最前線のひとつは自動走行であろう．従来のルールベースを超える E2E 的発想では，周囲の行動を外生的に予測し，その上で自車だけを最適化すればよいと考えられがちであった．しかし実際の交通は，相手もまたこちらを見て応答する相互作用の場である．Furuhashi and Hato（2026）は，この限界を正面から捉え，予測依存型の制御から，相互作用そのものを均衡埋め込みで扱う I2I 型の自動運転へと理論の重心を移している．そこでは，shared constraints の下での variational generalized Nash equilibrium，ICNN による学習可能なコスト設計，そして equilibrium-embedded predictive control が統合され，E2E を越えて現実空間の内生性に向き合う知能の姿が模索されている．さらに彼らは，この枠組みを，これまでにない歩行者と自動走行の混在空間における最適制御と最適設計の理論へと拡張しようとしている．

本書が学部生・大学院生に伝えたいのは，まさにこうしたダイナミックな研究のプロセスとその基礎となる理論のバリエーションである．行動モデル，ネットワーク配分，最適化，機械学習は，互いに隣接する技法ではない．それらは，人間の行動がネットワークを通じて都市を変え，その都市の設計が再び人間の行動を変えるという現実の循環構造に迫ろうとする，ひとつの知の系譜である．**?**] から**?**]，**?**]，**?**]，**?**]，**?**] へと至る流れは，単なる理論の並列ではなく，観測，均衡，設計，学習を再接続し続けてきた歴史である．そして Matsunaga and Hato（2026），Ogawa and Hato（2026），Furuhashi and Hato（2026）に見られるように，その流れは今，公共交通計画，日々の経路選択，自動走行の制御という異なる対象を通じて，新たな段階に入りつつある．理論を下敷きに新たな駅まち空間を設計しなおすこと．格差を是正しうる公共交通を構想し導入すること．今までにない都市と地域を構想し，計画し，実装し，運営すること．そのための基礎理論を，本書を通じて学んでもらいたい．都市と交通を学ぶとは，変わりゆく現実を理解するだけでなく，失われつつある場所と壊れた風景の前で，それでもなお次の危機に向けた新たな空間を構想し直す力を身につけることなのである．

参考文献

第 2 章

機械学習の基礎

2.1 機械学習の基礎

機械学習 (machine learning) は，観測データから規則性を抽出し，未知の入力に対する予測や意思決定を可能にする方法論である．しかし，その中心課題は単なる経験的な当てはめではない．観測標本を生み出した確率分布を，どのようなモデル族によって近似し，その近似をどのような最適化問題として解くかという二つの問いが，多くの手法の背後にある．本章では，この視点を軸として，損失関数，勾配法，誤差逆伝播法，ニューラルネットワーク，さらに画像・系列・言語を扱う代表的構造へと議論を進める．

本章の目標は三つある．第一に，機械学習を「確率分布の学習と最適化の問題」として統一的に捉えることである．第二に，教師あり学習 (supervised learning) を中心として，経験リスク最小化 (empirical risk minimization; ERM) と汎化 (generalization) の基礎概念を定式化することである．第三に，現代的な深層学習 (deep learning) の主要要素である確率的勾配降下法，誤差逆伝播法，畳み込みニューラルネットワーク (convolutional neural network; CNN)，再帰型ニューラルネットワーク (recurrent neural network; RNN)，Transformer が，それぞれどのような問題意識と計算上の制約から導かれたかを理解することである．

2.1.1 機械学習の歴史

機械学習の歴史を学ぶ必要があるのは，現在広く用いられている手法が，単に性能競争の結果として現れたのではなく，表現力，計算資源，データ量，最適化の難しさという四つの制約に対する応答として形成されてきたからである．ある時代の主流手法は，その時点で利用可能な計算機とデータのもとで，どの程度複雑な関数を学習でき，どの程度安定に最適化できるかという条件によって規定されていた．この見取り図を先に持つことは，後に学ぶ CNN，RNN，Transformer を個別の技巧としてではなく，問題構造に応じた帰結として理解するために重要である．

初期のパターン認識 (pattern recognition) では，主たる課題は観測ベクトルからクラスを識別する判別規則を設計することであった．ここでは，特徴抽出は人手で設計されることが多く，識別器は線形判別，最近傍法，判別分析など比較的単純な形をとった．この段階では，モデルの表現力は限定的であったが，そのぶん計算量は制御しやすく，少量のデータでも扱いやすかった．他方で，入力表現そのものを学習する能力が弱く，複雑な知覚課題には限界があった．

これに対して統計的学習 (statistical learning) は，有限標本からの推定と汎化誤差の制御を理論的

に扱う枠組みを整備した．経験リスク最小化，正則化，構造的リスク最小化，カーネル法などは，モデルの容量と汎化性能の折り合いをどのように付けるかという問いに答えるものである．この流れでは，表現力の拡張と同時に，過学習を避けるための理論的統制が重視された．すなわち，機械学習は単に当てはまりのよい関数を探す問題ではなく，未知データに対しても安定に振る舞う関数を推定する問題であるという認識が明確になった．

ニューラルネットワーク (neural network) の発想自体は古いが，1980 年代に誤差逆伝播法が広まったことで，多層モデルの学習が現実的な手続きとして定着した．ここで重要なのは，ニューラルネットワークが高い表現力を持ちながら，同時に最適化の難しさを強く抱え込む点である．浅いモデルでも非線形関数近似は可能であったが，計算資源が限られ，データ量も小さく，初期化や活性化関数の設計も未成熟であったため，深いモデルは長らく安定に学習しにくかった．したがって，表現力だけでは実用的成功は保証されず，それを支える最適化技術と計算基盤が不可欠であった．

2000 年代後半以降の深層学習の成功は，この四つの制約が同時に緩和されたことによって説明できる．第一に，GPU などの計算資源の発展により，大規模な行列演算を反復する訓練が実用化した．第二に，Web やセンサの普及によって大規模データが利用可能になった．第三に，ReLU 系活性化関数，適切な初期化，正規化，SGD の改良などにより，深いネットワークの最適化が容易になった．第四に，深い階層構造が画像・音声・言語における多段の表現学習に適していることが経験的に確認された．この結果，特徴量設計の重心が人手から学習へと移った．

現代の基盤モデル (foundation model) や大規模モデル (large-scale model) は，この延長線上に位置する．大規模事前学習によって汎用的な表現を獲得し，その後に少量の追加データや指示で多様な下流課題へ適応するという発想は，モデルの表現力とデータ量を極限まで押し広げた結果である．ただし，その基盤にあるのは依然として，条件付き分布や系列分布の学習を，巨大な最適化問題として解くという構図である．

この歴史的流れを各構造に結びつけると，CNN は画像に固有な局所性と平行移動対称性を取り込むために現れ，RNN は系列データの時間依存を表現するために導入され，Transformer は RNN の逐次性と長距離依存性の弱さを克服するために発展した．したがって，以後の節で扱う個々のモデルは，すべて「どのような構造仮定を置けば，限られた計算のもとで確率分布をうまく学習できるか」という共通問題に対する別々の答えである．次節では，この問題を教師あり学習の基本設定として明示的に定式化する．

2.1.2　機械学習の基本設定

機械学習の議論を精密に進めるためには，まず何を観測し，何を予測し，何を最適化するのかを明確にしなければならない．直感的には，入力から出力への対応を学ぶことが目的であるが，その背後では未知のデータ生成分布のもとで予測誤差を小さくするという問題が立てられている．とりわけ教師あり学習では，入力と正解出力が対になった標本が与えられるため，確率的定式化と最適化問題との対応がもっとも見えやすい．

().1　定義　教師あり学習では，訓練データセットを

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}$$

と書く．ここで，$x_i \in \mathcal{X}$ は第 i 標本の入力，$y_i \in \mathcal{Y}$ は対応する出力，n は標本数，$\mathcal{X}$ と $\mathcal{Y}$ はそれぞれ入力空間と出力空間である．通常は，各対 (x_i, y_i) が未知の同時分布 $p_{\mathrm{data}}(x, y)$ から独立同分布に従って生成されたと仮定する．この仮定は理想化ではあるが，訓練データと将来のデータが同種の母集団から来るという汎化の前提を数学的に表現している．

学習器はパラメータ (parameter)θ を持つモデル f_θ として表される．$f_\theta(x)$ は入力 x に対する予測値であり，その形は問題設定に応じて異なる．回帰 (regression) では $\mathcal{Y}$ は実数または実ベクトルであり，$f_\theta(x)$ は平均値や連続量の予測を返す．分類 (classification) では $\mathcal{Y}$ は有限個のクラス集合であり，$f_\theta(x)$ はクラス確率やロジット (logit) を返すことが多い．いずれにせよ，θ はモデルの自由度を定める未知量であり，学習とは θ をデータから推定することである．

実際の学習では，データは訓練集合，検証集合，テスト集合に分割される．訓練集合はパラメータ更新に用いられ，検証集合はハイパーパラメータの選択や早期終了の判断に用いられ，テスト集合は最終的な汎化性能の評価に用いられる．この分割が必要なのは，同じデータでモデルの選択と性能評価を同時に行うと，評価が楽観的に歪むからである．とくに深層学習では，アーキテクチャ，学習率，正則化強度など多くの設計選択があるため，検証集合の役割は本質的である．

教師あり学習の中心概念は経験リスク最小化である．損失関数 (loss function) を $\ell(y, f_\theta(x))$ と書くと，経験リスクは

$$\hat{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\theta(x_i))$$

で定義される．ここで ℓ は予測 $f_\theta(x_i)$ が正解 y_i からどれだけ外れているかを測る関数であり，$\hat{R}_n(\theta)$ は訓練データ上の平均誤差である．他方，真に最小化したい量は未知分布に関する期待損失

$$R(\theta) = \mathrm{E}_{(x,y)\sim p_{\mathrm{data}}} \left[\ell(y, f_\theta(x))\right]$$

であり，これを期待リスクまたは汎化誤差と呼ぶ．経験リスク最小化は，観測できない $R(\theta)$ を，その標本平均である $\hat{R}_n(\theta)$ に置き換えて最適化する考え方である．

このとき重要なのは，モデルが単に点予測関数としてではなく，条件付き分布 $p(y|x)$ の近似として理解できることである．すなわち，$f_\theta(x)$ はしばしば直接の予測値ではなく，条件付き分布 $p_\theta(y|x)$ を指定するためのパラメータを返す．たとえば回帰では，$f_\theta(x)$ を条件付き平均 $\mu_\theta(x)$ とみなして $p_\theta(y|x)$ をガウス分布で表すことが多い．分類では，$f_\theta(x)$ がクラスごとのロジットを返し，それを softmax に通してクラス確率 $p_\theta(y = k|x)$ を得る．この対応により，損失関数は確率モデルの負の対数尤度として自然に導かれる．

さらに，損失関数と条件付き分布の関係を理解すると，最適予測器の意味も明確になる．たとえば二乗損失のもとでは，各入力 x に対する最適予測は条件付き期待値 $\mathrm{E}[Y|X = x]$ である．分類で 0-1 損失を考えれば，最適予測は事後確率 $p(y|x)$ が最大のクラスを返す規則になる．したがって，機械学習の目標は単なるラベルの記憶ではなく，条件付き分布の構造を十分によく近似し，適切な決定規則へ変換することである．

以上の定式化により，問題は「どの損失関数を選び，どのような確率モデルを仮定するか」に帰着する．回帰と分類が異なるのは出力空間の性質だけではなく，仮定する確率モデルと対応する損

失が異なるためである．次節では，この対応を最尤推定と最大事後確率推定の観点から詳しく導き，損失最小化がどのような最適化問題になるかを整理する．

2.1.3　損失関数と最適化

損失関数を導入する理由は，学習の目的を数理的に定義し，パラメータ推定を最適化問題へ変換するためである．経験的には二乗誤差やクロスエントロピーがよく用いられるが，これらは便宜的に選ばれているわけではない．適切な確率モデルを仮定すると，それらは最尤推定 (maximum likelihood estimation; MLE) や最大事後確率推定 (maximum a posteriori; MAP) の帰結として現れる．したがって，損失の選択は「どの誤差を罰したいか」という感覚的判断だけではなく，「データ生成過程をどのようにモデル化するか」という統計的判断でもある．

().1　定義　最尤推定では，パラメータ θ を，訓練データの条件付き尤度を最大化する量として定める．すなわち

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta} \prod_{i=1}^{n} p_\theta(y_i|x_i) = \arg\max_{\theta} \sum_{i=1}^{n} \log p_\theta(y_i|x_i)$$

である．対数は単調増加であるため，尤度最大化は負の対数尤度の最小化と等価である．以後，負の対数尤度を損失関数として用いると，確率推定と最適化が一つの枠組みに統合される．

回帰において，出力 y_i が平均 $\mu_\theta(x_i)$，分散 σ^2 のガウス分布に従うと仮定しよう．ここで $\mu_\theta(x_i)$ はモデルが入力 x_i から出力する条件付き平均，σ^2 は観測雑音の分散である．このとき

$$p_\theta(y_i|x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mu_\theta(x_i))^2}{2\sigma^2}\right)$$

であるから，負の対数尤度の総和は定数項を除いて

$$\sum_{i=1}^{n} -\log p_\theta(y_i|x_i) = \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \mu_\theta(x_i))^2 + \mathrm{const.}$$

となる．したがって，平均二乗誤差 (mean squared error; MSE)

$$\mathcal{L}_{\mathrm{MSE}}(\theta) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \mu_\theta(x_i))^2$$

は，ガウス雑音仮定のもとでの最尤推定に対応している．ここで n は標本数であり，各誤差を平均することでデータ数に依らない尺度を得ている．

分類では，出力が K 個のクラスのいずれかをとるとする．モデルが入力 x_i に対してクラスごとのロジット $z_k(x_i)$ を返すとき，softmax により

$$\pi_{\theta,k}(x_i) = \frac{\exp(z_k(x_i))}{\sum_{j=1}^{K} \exp(z_j(x_i))}$$

を定義すると，$\pi_{\theta,k}(x_i)$ はクラス k の条件付き確率 $p_\theta(y_i = k|x_i)$ と解釈できる．正解ラベルを one-hot ベクトル $y_i = (y_{i1}, \ldots, y_{iK})$ で表し，$y_{ik} \in \{0, 1\}$ を「標本 i がクラス k に属するか」を表す指示変数とすると，負の対数尤度は

$$\mathcal{L}_{\mathrm{CE}}(\theta) = -\sum_{i=1}^{n}\sum_{k=1}^{K} y_{ik} \log \pi_{\theta,k}(x_i)$$

となる．これはクロスエントロピー損失 (cross-entropy loss) であり，真のラベル分布とモデル分布のずれを測る量として理解できる．

MAP 推定では，さらにパラメータの事前分布 $p(\theta)$ を導入し，

$$\hat{\theta}_{\mathrm{MAP}} = \arg\max_{\theta} \left\{ \sum_{i=1}^{n} \log p_\theta(y_i|x_i) + \log p(\theta) \right\}$$

を解く．これは負の対数をとれば，データ適合項に加えて $-\log p(\theta)$ という正則化項を課すことに等しい．たとえば $p(\theta) \propto \exp(-\lambda\|\theta\|_2^2/2)$ というガウス事前分布を置けば，$\lambda\|\theta\|_2^2/2$ という L_2 正則化が現れる．同様に，ラプラス事前分布を置けば L_1 正則化が現れる．したがって，正則化は経験的な細工ではなく，パラメータに対する事前信念を導入した統計推定として理解できる．

もっとも，損失関数が定まれば問題が簡単になるわけではない．線形回帰やロジスティック回帰の一部では凸最適化が得られるが，深いニューラルネットワークでは一般に目的関数は非凸 (nonconvex) である．すなわち，勾配がゼロとなる停留点の周囲には，局所最小点，鞍点 (saddle point)，あるいは曲率が小さい平坦領域が存在しうる．ヘッセ行列を $H(\theta)$ と書けば，停留点で $H(\theta)$ の固有値がすべて正なら局所最小，正負が混在すれば鞍点である．深層学習においては，悪い局所解そのものよりも，高次元空間に多数現れる鞍点や，曲率の偏りによって進行が遅くなる平坦領域のほうが，しばしば実践上の難所となる．

さらに，最小化された訓練損失が小さいことと，汎化性能が高いことは同義ではない．平坦な最小点はしばしば汎化に有利だと経験的に言われるが，その因果関係は単純ではなく，パラメータ化の仕方や最適化アルゴリズムにも依存する．ここで重要なのは，機械学習における最適化は，解析的に唯一解を求める問題ではなく，巨大な非凸目的関数の中から，計算可能で汎化も良好な解を探索する過程だという点である．

この探索を現実的な時間で実行するために，深層学習では勾配法が中心的役割を果たす．とくに大規模データでは，全データに対する勾配を毎回計算することは高価すぎる．次節では，この問題に対する標準的解法である確率的勾配降下法を導入し，その統計的性質と実装上の意味を整理する．

2.1.4 確率的勾配降下法 (SGD)

損失関数が定まった後に必要なのは，その最小値へ向かってパラメータを更新する具体的な計算法である．とくに深層学習では，パラメータ数もデータ数も大きいため，厳密解を求めるよりも反復的な近似最適化が現実的である．このとき，全訓練データを毎回用いる方法は統計的には素直であっても，計算量とメモリ使用量の点でしばしば実用的でない．確率的勾配降下法 (stochastic gradient descent; SGD) は，この制約のもとで勾配情報を効率よく利用するための基本アルゴリズムである．

訓練目的関数を

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(\theta), \qquad \ell_i(\theta) = \ell(y_i, f_\theta(x_i))$$

と書く．ここで $L(\theta)$ は平均損失，$\ell_i(\theta)$ は標本 i に対する個別損失，n は訓練標本数である．バッチ勾配降下法 (batch gradient descent) では，各反復 t における更新は

$$\theta_{t+1} = \theta_t - \eta_t \nabla L(\theta_t) = \theta_t - \eta_t \frac{1}{n} \sum_{i=1}^{n} \nabla \ell_i(\theta_t)$$

で与えられる．ここで θ_t は時刻 t のパラメータ，$\eta_t > 0$ は学習率 (learning rate) である．この更新は目的関数の真の勾配を用いるため安定であるが，大規模データでは毎回すべての標本を読む必要がある．

これに対して SGD では，訓練集合からサイズ b のミニバッチ B_t を無作為に選び，

$$g_t = \frac{1}{b} \sum_{i \in B_t} \nabla \ell_i(\theta_t), \qquad \theta_{t+1} = \theta_t - \eta_t g_t$$

と更新する．ここで b はバッチサイズ，g_t はミニバッチ勾配である．B_t を一様にサンプリングすれば，条件付き期待値について

$$\mathrm{E}[g_t \mid \theta_t] = \nabla L(\theta_t)$$

が成り立つ．すなわち，ミニバッチ勾配は真の勾配の不偏推定量である．この事実が，SGD を単なる近似計算ではなく，統計的に意味のある勾配推定法として位置づけている．

ミニバッチ化の効果を理解するには，勾配の分散に注目するとよい．個別勾配 $\nabla \ell_i(\theta_t)$ がある共分散行列 $\Sigma(\theta_t)$ を持つと近似すれば，復元抽出に基づく単純化のもとで

$$\mathrm{Var}(g_t \mid \theta_t) \approx \frac{1}{b} \Sigma(\theta_t)$$

である．したがって，バッチサイズ b を大きくすると勾配推定の分散はおおむね $1/b$ に比例して減少する．これは，大きなバッチでは更新方向が安定し，小さなバッチでは雑音が強くなることを意味する．雑音は収束を遅らせうる一方で，鞍点や鋭い谷から抜け出す助けになる場合もあるため，バッチサイズの選択は統計的効率と探索性の折り合いである．

実装上，ミニバッチ化が重要なのは，第一にメモリ制約のためであり，第二に計算資源の並列利用のためである．GPU や TPU は多数の標本に対する同型演算をまとめて実行することで高いスループットを発揮するが，全データを一度に載せることは通常できない．ミニバッチは，行列演算の効率を確保しつつ，メモリ内で処理可能な単位にデータを分割する役割を持つ．また，オンラインに到着するデータや巨大データセットに対しても，局所的な勾配情報だけで更新を続けられる点で，大規模学習の前提をなしている．

().1　アルゴリズム　SGD の基本形は単純である．各エポックでデータをシャッフルし，ミニバッチごとに順伝播，損失計算，勾配計算，パラメータ更新を行う．ここで「エポック」とは訓練集合全体を一巡する単位を指す．実際には，学習率の減衰，勾配クリッピング，重み減衰などを組み合わせることが多いが，中心にあるのは不偏な勾配推定を反復的に用いて目的関数を下げるという構図である．

SGD の派生として Momentum は過去の更新方向を指数移動平均し，振動を抑えながら進行方向を安定化する．Adam は一次モーメントと二次モーメントの推定に基づき，各パラメータに適応的な学習率を割り当てる．これらは実務上きわめて有用であるが，深層学習の根幹がミニバッチ勾配に基づく SGD にあることは変わらない．勾配法が機能する前提は，各反復でパラメータに関する勾配を効率よく計算できることであり，そのための決定的技術が誤差逆伝播法である．次節では，連鎖律に基づく勾配計算の仕組みを導く．

2.1.5　誤差逆伝播法

深いネットワークを学習するには，多数のパラメータそれぞれについて損失の勾配を求める必要がある．もし各パラメータを独立に微分し，そのたびに順方向計算をやり直すなら，計算量は現実的でなくなる．誤差逆伝播法 (backpropagation) が必要なのは，複合関数として構成されたモデルの勾配を，計算グラフと連鎖律を用いて一度の順伝播と一度の逆伝播で効率よく求めるためである．この方法により，パラメータ数が多くても，計算量はグラフの辺数にほぼ線形に比例する．

計算グラフ (computational graph) では，各演算をノード，依存関係を辺として表す．L 層の全結合ネットワークを例にとると，入力を $h^{(0)} = x$ として，各層 $l = 1, \dots, L$ について

$$a^{(l)} = W^{(l)} h^{(l-1)} + b^{(l)}, \qquad h^{(l)} = \phi^{(l)}(a^{(l)})$$

と書ける．ここで $W^{(l)}$ は第 l 層の重み行列，$b^{(l)}$ はバイアスベクトル，$a^{(l)}$ は活性化関数適用前の線形結合，$h^{(l)}$ は層出力，$\phi^{(l)}$ は活性化関数である．教師信号を y，最終損失を $\mathcal{L}(h^{(L)}, y)$ と書けば，求めたいのは各 $W^{(l)}$ と $b^{(l)}$ に関する偏微分である．

().1　定義　逆伝播では，各層の前活性化 $a^{(l)}$ に関する損失の勾配

$$\delta^{(l)} = \frac{\partial \mathcal{L}}{\partial a^{(l)}}$$

を誤差信号と呼ぶ．出力層では

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial h^{(L)}} \odot \phi^{(L)\prime}(a^{(L)})$$

であり，$\odot$ は要素ごとの積，$\phi^{(L)\prime}$ は活性化関数の導関数である．中間層では連鎖律により

$$\delta^{(l)} = \Big((W^{(l+1)})^{\top} \delta^{(l+1)} \Big) \odot \phi^{(l)\prime}(a^{(l)}), \qquad l = L-1, \dots, 1$$

という再帰式が成り立つ．すなわち，上位層から伝わってきた誤差を重み行列の転置で引き戻し，その層の局所微分で修正することで，下位層の勾配情報が得られる．

この誤差信号が得られれば，各パラメータに関する勾配は直ちに計算できる．単一標本に対しては

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} (h^{(l-1)})^{\top}, \qquad \frac{\partial \mathcal{L}}{\partial b^{(l)}} = \delta^{(l)}$$

である．ミニバッチ学習では，各標本に対するこれらの勾配を平均したものがバッチ勾配となる．ここで $h^{(l-1)}$ が必要なのは，重み行列 $W^{(l)}$ が前層出力と線形に結びついているからであり，誤差信号 $\delta^{(l)}$ と入力 $h^{(l-1)}$ の外積として勾配が現れる．

順伝播時の中間値を保存する必要があるのも，この式から理解できる．逆伝播では $\phi^{(l)\prime}(a^{(l)})$ や $h^{(l-1)}$ が必要になるため，前活性化 $a^{(l)}$ と層出力 $h^{(l)}$ を保持しておかないと，逆向き計算のたびに順方向を再計算しなければならない．したがって，誤差逆伝播法は計算量を節約する代わりに，中間活性を記憶するメモリを要求する．この時間と空間の交換は，深いモデルや長い系列を扱う際にとくに重要である．

逆伝播が効率的である理由は，逆向きモード自動微分 (reverse-mode automatic differentiation) と同じ原理を用いているからである．出力がスカラー損失一つであるとき，各ノードから損失への感度を一度だけ伝播すれば，すべてのパラメータの勾配が得られる．これに対して前向きモードで各パラメータごとに微分を流すと，パラメータ数に比例する回数の計算が必要になる．深層学習では通常，出力次元よりもパラメータ数のほうがはるかに大きいため，逆伝播の利点は決定的である．

もっとも，深いネットワークでは勾配そのものが安定に伝わらないことがある．層ごとのヤコビアンを $J^{(l)}$ と書けば，下位層への勾配は概ねそれらの積

$$\frac{\partial \mathcal{L}}{\partial h^{(l)}} \propto J^{(l+1)} J^{(l+2)} \cdots J^{(L)}$$

に支配される．この積のノルムが繰り返し 1 より小さければ勾配消失 (vanishing gradient)，大きければ勾配爆発 (exploding gradient) が起こる．深層化と長系列化に伴ってこの問題は顕著になり，活性化関数，初期化，正規化，残差接続，ゲーティングなどの工夫が必要になる．

このように，誤差逆伝播法は深層学習を可能にした計算技術であるが，その効果はネットワークの構造と強く結びついている．次節では，そもそもニューラルネットワークがどのような関数族を表し，なぜ非線形性が不可欠なのかを整理する．

2.1.6　ニューラルネットワークの基本構造

ニューラルネットワークを学ぶ必要があるのは，深層学習におけるほとんどすべてのモデルが，その変形または拡張として理解できるからである．CNN，RNN，Transformer はいずれも特殊な構造を持つが，その基本単位は線形変換と非線形活性化の反復にある．したがって，まずパーセプトロン，多層パーセプトロン，活性化関数，出力層の意味を押さえることが，後続の複雑なアーキテクチャを理解する前提となる．

パーセプトロン (perceptron) は，もっとも基本的な線形判別器である．入力 $x \in \mathcal{X}$ をベクトルとし，重みベクトルを w，バイアスを b とすると，その決定関数は

$$\hat{y} = \mathrm{sign}(w^\top x + b)$$

と書ける．ここで $w^\top x$ は入力と重みの内積，sign は符号関数であり，超平面による二値分類を表す．パーセプトロンは線形分離可能な問題には有効であるが，入力空間における複雑な非線形境界を直接表すことはできない．この限界を超えるために，中間表現を導入した多層パーセプトロン (multilayer perceptron; MLP) が用いられる．

MLP では，各層が

$$h^{(l)} = \phi^{(l)}(W^{(l)} h^{(l-1)} + b^{(l)})$$

という形で定義される．ここで $h^{(0)} = x$ は入力，$h^{(l)}$ は第 l 層の隠れ表現，$W^{(l)}$ と $b^{(l)}$ は学習されるパラメータ，$\phi^{(l)}$ は活性化関数である．最終層の出力は課題に応じて変わる．回帰では線形出力をそのまま使うことが多く，二値分類では sigmoid 関数で確率に写し，多クラス分類では softmax を用いてクラス確率へ変換する．

非線形性が必要であることは，数式から直ちに分かる．もしすべての活性化関数が恒等写像，すなわち $\phi^{(l)}(u) = u$ であるなら，二層以上のネットワークでも

$$h^{(L)} = W_{\text{eff}} x + b_{\text{eff}}$$

という単一のアフィン変換にまとめられる．ここで W_{eff} は各層の重み行列の積，b_{eff} はバイアス項をまとめたベクトルである．したがって，線形変換を何層重ねても，表現力は本質的に一層の線形モデルを超えない．非線形活性化は，関数クラスを真に拡張し，高次の特徴や複雑な決定境界を表現するために不可欠である．

活性化関数にはそれぞれ役割と副作用がある．sigmoid 関数

$$\sigma(u) = \frac{1}{1 + \exp(-u)}$$

は出力を $(0, 1)$ に収めるため確率解釈と相性がよいが，大きな正負の入力で勾配が小さくなりやすい．双曲線正接関数 $\tanh(u)$ は出力が $(-1, 1)$ に中心化されるため学習しやすい場面があるが，やはり飽和による勾配消失を起こしうる．ReLU は

$$\mathrm{ReLU}(u) = \max(0, u)$$

で定義され，正の領域で勾配が保たれるため深層学習を大きく前進させた．近年の Transformer では，標準正規分布の累積分布関数を Φ として $\mathrm{GELU}(u) = u\Phi(u)$ と定義される GELU がよく用いられる．これは入力を滑らかにゲートする働きを持ち，深いモデルの最適化と相性がよい．

普遍近似定理 (universal approximation theorem) は，適切な非線形活性化を持つ十分広い一隠れ層ネットワークが，コンパクト集合上の連続関数を任意精度で近似できることを述べる．この結果はニューラルネットワークの表現力を保証するが，それだけで深いネットワークの優位性が自動的に示されるわけではない．実際には，同じ関数を浅いネットワークで表すには非常に大きな幅が必要になることがあり，深さは合成構造を持つ関数を効率よく表す手段として重要である．すなわち，深いモデルの意義は「表現できるか否か」だけでなく，「どれだけ少ないパラメータで，どれだけ学習しやすく表現できるか」にある．

以上より，ニューラルネットワークの基本単位は，線形写像，非線形活性化，目的に応じた出力層から成ることが分かる．しかし高い表現力は同時に過学習の危険を伴う．次節では，訓練誤差の最小化と未知データへの汎化との緊張関係を整理し，正則化の役割を考える．

2.1.7 正則化と汎化

機械学習で本当に必要なのは，訓練データによく合うモデルではなく，未知データに対しても安定に機能するモデルである．正則化 (regularization) を学ぶ理由は，モデルの表現力が高くなるほ

ど，訓練誤差を小さくするだけでは不十分になるからである．とくに深層学習では，過剰な自由度が過学習を招く一方で，十分な表現力がなければ複雑な分布を捉えられない．正則化はこの緊張関係を制御し，汎化性能を改善するための原理である．

過学習 (overfitting) とは，モデルが訓練集合に特有の偶然的変動や雑音まで取り込んでしまい，訓練誤差は小さいにもかかわらずテスト誤差が大きくなる現象をいう．逆に，モデルが単純すぎて訓練誤差すら十分に下がらない状態をアンダーフィット (underfitting) という．前者ではモデル容量がデータ量に比して大きすぎ，後者では表現力が不足している．したがって，良い学習とは，単に大きなモデルを選ぶことでも，小さなモデルを選ぶことでもなく，課題に見合った容量制御を行うことである．

この関係を理解する一つの手がかりが，二乗損失におけるバイアス・バリアンス分解 (bias-variance decomposition) である．真の回帰関数を $f^\star(x) = \mathrm{E}[Y|X = x]$，学習データ $\mathcal{D}$ から得られる推定器を $\hat{f}_{\mathcal{D}}(x)$，観測雑音の分散を $\sigma_\varepsilon^2 = \mathrm{Var}(Y|X = x)$ とすると，固定した入力 x における予測誤差の期待値は

$$\mathrm{E}_{\mathcal{D},Y}\left[(Y - \hat{f}_{\mathcal{D}}(x))^2\right] = \sigma_\varepsilon^2 + \left(\mathrm{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(x)] - f^\star(x)\right)^2 + \mathrm{E}_{\mathcal{D}}\left[\left(\hat{f}_{\mathcal{D}}(x) - \mathrm{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(x)]\right)^2\right]$$

と書ける．右辺の第一項は不可避な雑音，第二項は系統的なずれであるバイアス，第三項は学習データの揺らぎに対する感度であるバリアンスを表す．一般に，単純なモデルは高バイアス・低バリアンス，複雑なモデルは低バイアス・高バリアンスの傾向を持つ．

もっとも基本的な正則化は，目的関数にパラメータノルムの罰則を加える方法である．L_2 正則化は $\lambda\|\theta\|_2^2/2$ を，L_1 正則化は $\lambda\|\theta\|_1$ を損失に加える．ここで $\lambda > 0$ は正則化強度であり，$\|\theta\|_2$ はユークリッドノルム，$\|\theta\|_1$ は各成分の絶対値和である．前節で見たように，これらはそれぞれガウス事前分布とラプラス事前分布を課した MAP 推定として解釈できる．L_2 はパラメータを滑らかに縮小し，L_1 は疎な解を促しやすい．いずれも，無制約に複雑な関数を選ぶことを抑える容量制御とみなせる．

深層学習では，明示的な罰則以外にも多くの正則化手段が使われる．Dropout では，訓練時に各隠れユニットを確率的に無効化し，ネットワークが特定の経路に過度に依存することを防ぐ．記号的には，隠れ表現 h に対してベルヌーイマスク m を掛けた $\tilde{h} = m \odot h$ を用いる操作とみなせる．Early Stopping は，検証誤差が悪化し始める前に訓練を止める方法であり，反復最適化それ自体を暗黙の正則化として利用する．Batch Normalization は，ミニバッチ平均 μ_B と分散 σ_B^2 を用いて

$$\hat{a} = \frac{a - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \qquad y = \gamma\hat{a} + \beta$$

と正規化する．ここで a は正規化前の活性，ϵ は数値安定化のための小定数，γ, β は学習可能なスケールとシフトである．これは主として最適化を安定化する技法であるが，ミニバッチ統計量の揺らぎを通じて一定の正則化効果も持つ．

Data Augmentation は，入力にラベル不変な変換を加えることで，モデルに望ましい不変性を学習させる方法である．画像であれば平行移動，反転，切り出し，色変換などが典型であり，系列や言語でもノイズ付与やマスク化などが利用される．これは，単に標本数を人工的に増やす手法では

なく，「この変換では意味が変わらない」という事前知識を学習問題に埋め込む操作と解釈できる．その意味で，アーキテクチャ設計と同様に，分布に関する帰納バイアス (inductive bias) を与える手段である．

近年は，モデルサイズを増やすとテスト誤差が一度悪化した後で再び改善する double descent も観測されている．これは古典的な「モデルが複雑になるほど汎化は単調に悪化する」という単純図式が十分でないことを示している．しかし，この現象もまた，補間可能な過剰パラメータ領域であっても，どの解が最適化によって選ばれるかが重要であることを示すにすぎない．すなわち，汎化は依然として，データ，モデル容量，最適化，正則化の相互作用として理解すべき問題である．

ここまでの議論は，主として全結合ネットワークを念頭に置いていた．しかし現実のデータには，画像の局所性や系列の時間依存のような明確な構造が存在する．こうした構造を活用することで，表現効率と汎化性能を同時に高めることができる．次節では，画像に対する代表的な帰納バイアスを実装した CNN を扱う．

2.1.8 CNN

画像に対して全結合層だけを用いることが非効率である理由は，画像が高次元でありながら，局所的で平行移動に対して類似した構造を持つからである．たとえば，高さ H，幅 W，チャネル数 C の画像を一つのベクトルに平坦化して全結合層へ入力すると，隠れ層のユニット数に比例して巨大な数のパラメータが必要になる．しかも，この表現では近くにある画素と遠くにある画素の区別が消え，画像の空間構造が活かされない．CNN は，この問題を局所結合と重み共有によって解決する．

畳み込み層では, 各出力ユニットが入力全体ではなく局所領域だけを見る．これを受容野 (receptive field) と呼ぶ．さらに，入力の異なる位置で同じカーネルを使い回すことで重み共有を行う．二次元入力 X とカーネル K に対する離散畳み込みを，出力位置 (i, j) で

$$(X * K)_{i,j} = \sum_{u=0}^{r-1} \sum_{v=0}^{s-1} K_{u,v} X_{i+u,j+v}$$

と定義する．ここで r, s はカーネルの高さと幅，u, v はカーネル内部の添字，i, j は出力位置を表す．実際の画像ではチャネル方向の和も加わるが，本質は局所領域に対して同一の線形演算を空間全体で適用する点にある．

この構造は二つの利点をもたらす．第一に，パラメータ数が大幅に削減される．全結合層では入力次元に比例して重み数が増えるのに対し，畳み込み層ではカーネルサイズに比例するだけである．第二に，平行移動等変性 (translation equivariance) が得られる．平行移動演算を T_Δ，畳み込み演算を $\mathcal{C}$ と書けば，

$$\mathcal{C}(T_\Delta X) = T_\Delta(\mathcal{C}(X))$$

が成り立つ．すなわち，入力をずらせば出力も同じだけずれる．この性質により，同じ局所パターンを画像中のどこでも検出できる．

プーリング (pooling) は，局所領域の代表値をとることで空間解像度を下げ，わずかな位置ずれに対する不変性を高める操作である．最大値をとる max pooling と平均をとる average pooling が典

型である．畳み込みとプーリングを重ねると，浅い層ではエッジや局所テクスチャ，深い層ではより抽象的な形状や部品が表現されるようになる．また，層を重ねるにつれて受容野が広がるため，局所情報から大域的文脈へと表現が統合されていく．

CNN の歴史的発展も，構造仮定と計算資源の相互作用として理解できる．LeNet は文字認識で畳み込みの有効性を示した初期例であり，AlexNet は GPU と ReLU を活用して ImageNet で深層 CNN の優位を広く認知させた．VGG は小さなカーネルを多層に積む設計で深さの効果を明確にし，ResNet は

$$h^{(l+1)} = h^{(l)} + F(h^{(l)})$$

という残差接続によって，より深いネットワークの最適化を可能にした．ここで F は残差写像であり，恒等写像を近道として残すことで勾配伝播を助ける．

もっとも，CNN の帰納バイアスは画像のような格子状データには適していても，系列のように順序依存が本質となる問題にはそのままでは十分でない．時系列，文章，音声のようなデータでは，過去の情報をどのように状態として保持し，将来の予測に反映させるかが中心問題となる．次節では，そのために導入された RNN を扱う．

2.1.9　RNN

系列データを扱うためには，観測が独立ではなく，時間や位置に沿って依存していることを明示的に表現しなければならない．文章，音声，交通流時系列などでは，現在の観測や予測が過去の文脈に依存するため，入力を単に固定長ベクトルとして扱うだけでは不十分である．RNN が必要なのは，系列の結合分布を連鎖律に従って分解し，その文脈を隠れ状態として逐次的に要約できるからである．

長さ T の系列 $x_{1:T} = (x_1, \ldots, x_T)$ の結合分布は，確率の連鎖律により

$$p(x_{1:T}) = \prod_{t=1}^{T} p(x_t \mid x_{1:t-1})$$

と書ける．ここで $x_{1:t-1}$ は時刻 1 から $t-1$ までの過去系列である．条件付き生成や系列ラベリングでも同様に，現在の出力は過去の入力や過去の出力に依存する．この依存構造を有限次元の状態で近似するため，RNN は各時刻 t に隠れ状態 h_t を持ち，

$$h_t = \phi(W_{xh} x_t + W_{hh} h_{t-1} + b_h)$$

と更新する．ここで x_t は時刻 t の入力，h_t はその時点までの文脈を要約した隠れ状態，W_{xh} と W_{hh} は入力と前時刻状態に対する重み行列，b_h はバイアス，ϕ は活性化関数である．出力 o_t は通常

$$o_t = W_{hy} h_t + b_y$$

とし，必要に応じて softmax などへ通す．

この再帰式の直感は明快である．各時刻で新しい観測 x_t を取り込み，それ以前の要約 h_{t-1} と結合して新しい要約 h_t を作るのである．したがって RNN は，可変長系列を固定次元の状態遷移と

して扱う動的システムとみなせる．重み行列が時刻をまたいで共有されるため，系列長が変わっても同じモデルを適用できる点も重要である．

学習は時間方向に展開した計算グラフに対する誤差逆伝播, すなわち BPTT(backpropagation through time) によって行う．時刻ごとの損失を $\mathcal{L}_t$ とすると，総損失 $\mathcal{L} = \sum_t \mathcal{L}_t$ に対するある時刻 t の状態勾配は

$$\frac{\partial \mathcal{L}}{\partial h_t} = \frac{\partial \mathcal{L}_t}{\partial h_t} + \left(\frac{\partial h_{t+1}}{\partial h_t}\right)^\top \frac{\partial \mathcal{L}}{\partial h_{t+1}}$$

という再帰式に従う．ここで $\partial h_{t+1}/\partial h_t$ は時刻をまたぐヤコビアンであり，長い系列ではそれらの積が勾配を支配する．このため，固有値の大きさや活性化関数の導関数によって，勾配消失や勾配爆発が生じやすい．

LSTM(long short-term memory) や GRU(gated recurrent unit) が必要になったのは，この問題を緩和するためである．たとえば LSTM では，セル状態 c_t を

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \qquad h_t = o_t \odot \tanh(c_t)$$

と更新する．ここで f_t, i_t, o_t はそれぞれ忘却ゲート，入力ゲート，出力ゲート，$\tilde{c}_t$ は候補セル状態であり，いずれも時刻 t の入力と前時刻状態から計算される．重要なのは，セル状態が加法的な経路を持つため，勾配が長距離にわたって保たれやすいことである．GRU も同様に，より簡潔なゲーティングによって情報保持と更新を制御する．

RNN は長らく系列モデリングの中心にあったが，固定長の隠れ状態だけで長い文脈を圧縮することには限界がある．Encoder-Decoder 構造は，入力系列を文脈ベクトルに写し，それをもとに出力系列を生成することで機械翻訳などに成功したが，長文では情報ボトルネックが顕著になった．これを緩和したのが Attention であり，各出力時刻が入力系列全体の関連部分を直接参照できるようにした．この発想がさらに発展し，再帰そのものを不要にしたのが Transformer である．次節では，その構造を詳しく見る．

2.1.10 Transformer

Transformer を学ぶ必要があるのは，現代の大規模言語モデルや多くの生成モデルの中核がこの構造にあるからである．RNN は系列依存を表現できるが，計算が逐次的で並列化しにくく，遠く離れた要素間の依存を長い経路で伝えなければならない．この逐次性と長距離依存性の限界を克服するために，Transformer は系列内の要素同士を直接結び付ける Self-Attention を採用した．これにより，系列長に対する計算構造と表現の仕方が根本的に変わった．

長さ T の系列を，各トークンの埋め込みを並べた $T \times d$ の実数行列 H で表す．ここで T は系列長，d は埋め込み次元である．Self-Attention では，H からクエリ Q，キー K，バリュー V を

$$Q = HW^Q, \qquad K = HW^K, \qquad V = HW^V$$

により作る．W^Q, W^K, W^V は学習される重み行列である．各行はそれぞれ一つの位置に対応し，ある位置が他の位置をどれだけ参照すべきかを，クエリとキーの内積で決める．Scaled Dot-Product Attention は

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

で定義される．ここで d_k はクエリとキーの次元，softmax は各行ごとに適用されて注意重みを確率分布に変換する．$\sqrt{d_k}$ で割るのは，内積の分散が大きくなりすぎて softmax が飽和するのを防ぐためである．

この式の意味は，各位置が他のすべての位置に対して重み付き平均をとり，新しい表現を得るということである．RNN では時刻 t の情報が時刻 $t+1, t+2, \ldots$ を経由して遠方へ伝わるのに対し，Self-Attention では任意の二位置間が一回の演算で直接相互作用できる．したがって，長距離依存性に対する経路長は理論的に短くなり，勾配伝播も容易になる．また，各位置の計算を同時に行えるため，訓練時の並列化効率が高い．

Multi-Head Attention は，この相互作用を単一の重み付けに限定せず，異なる関係を並列に学習するための仕組みである．ヘッド数を M とすると，第 m ヘッドは

$$\mathrm{head}_m = \mathrm{Attention}(HW_m^Q, HW_m^K, HW_m^V)$$

で与えられ，全体の出力は

$$\mathrm{MHA}(H) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_M)W^O$$

となる．ここで W_m^Q, W_m^K, W_m^V は第 m ヘッド専用の射影行列，W^O は結合後の出力射影，Concat は特徴次元方向の連結を表す．複数ヘッドを用いることで，あるヘッドは局所的対応，別のヘッドは長距離依存，さらに別のヘッドは構文的関係といった異なるパターンを同時に捉えうる．

Transformer には再帰がないため，位置情報を別途与えなければ系列の順序が失われる．これを補うのが Position Encoding である．代表的な正弦波型位置符号化では，位置 t，次元添字 i に対して

$$p_{t,2i} = \sin\left(\frac{t}{10000^{2i/d}}\right), \qquad p_{t,2i+1} = \cos\left(\frac{t}{10000^{2i/d}}\right)$$

を定め，入力埋め込みに加える．これにより，モデルは相対的・絶対的な位置関係を連続的な表現として受け取ることができる．実際には学習可能な位置埋め込みが使われることも多いが，要点は「順序を表現しない自己注意機構に，系列順序の手がかりを与える」ことである．

RNN と比較した Transformer の利点は，並列化しやすく，長距離依存を扱いやすい点にある．他方で，全位置対の相互作用を計算するため，Self-Attention の計算量とメモリ量は系列長 T に対して概ね $O(T^2)$ で増大する．このため非常に長い系列では効率上の課題が残り，疎注意や線形注意など多くの改良が提案されている．それでも，自然言語処理を中心に Transformer が支配的となったのは，この計算コストを払ってなお得られる表現力と学習効率の利得が大きかったからである．

自己回帰モデル (autoregressive model) との関係も重要である．デコーダ型 Transformer では，未来のトークンを見ないように因果マスク (causal mask) を課し，

$$p_\theta(x_{1:T}) = \prod_{t=1}^{T} p_\theta(x_t \mid x_{1:t-1})$$

という系列分布を学習する．ここで各条件付き分布は，Self-Attention を通じて過去文脈全体に基づいて計算される．この枠組みを巨大データ上で事前学習したものが，大規模言語モデル (large language model; LLM) の基本形である．したがって Transformer は，本章の終点であると同時に，後に学ぶ生成モデルや強化学習と結び付く出発点でもある．

まとめ

本章では，機械学習を「確率分布の学習と最適化の問題」として捉える立場から，基礎概念を順に整理した．まず歴史的には，パターン認識から統計的学習，ニューラルネットワーク，深層学習へと進む流れを，表現力，計算資源，データ量，最適化という観点で読み直した．次に，教師あり学習の基本設定として，データ集合，モデル，パラメータ，経験リスク，汎化誤差，条件付き分布の対応を定式化した．そこから，損失関数が最尤推定や MAP 推定から自然に導かれること，深層学習の最適化が一般に非凸であることを確認した．

さらに，実際の学習を支える計算原理として，ミニバッチに基づく SGD と，連鎖律に基づく誤差逆伝播法を導入した．これにより，大規模データと多数のパラメータを持つモデルを現実的に学習できる理由が明確になった．そのうえで，ニューラルネットワークの基本構造を，線形変換，非線形活性化，出力層の組合せとして整理し，過学習と汎化の問題に対して正則化が果たす役割を考えた．最後に，画像の局所性を活かす CNN，系列の時間依存を表す RNN，長距離依存と並列化を両立する Transformer を順に見たことで，アーキテクチャとはデータ構造に応じた帰納バイアスの実装であることが理解できたはずである．これらの基礎は，強化学習や生成モデルへ進む際にも，その背後にある確率的定式化と最適化の考え方を見失わないための足場となる．

参考文献

2.2　強化学習

強化学習（reinforcement learning）は，環境との相互作用を通じて意思決定規則を学習し，長期的な累積報酬を最大化するための理論である．教師あり学習では入力と正解の対応が与えられ，教師なし学習では観測データの潜在構造の抽出が中心となるのに対し，強化学習では各時刻の行動に対して正解が即座に与えられるとは限らない．ある行動の評価は，その後に続く状態遷移と報酬列を通じて初めて定まり，その意味で遅延報酬を本質に含んでいる．

本章の目標は，強化学習を単なるアルゴリズムの集合としてではなく，確率的環境のもとで価値関数または方策を学習し，累積報酬を最適化する統一理論として理解することである．標準的な教科書的整理としては **?**] が広く参照されるが，本章ではそれを踏まえつつ，交通・都市工学の逐次意思決定問題にも接続しやすい形で議論を組み立てる．まず歴史的流れから問題意識を整理し，次にマルコフ決定過程によって標準的定式化を与える．そのうえで，多腕バンディット問題によって探索と活用の本質を切り出し，動的計画法，価値ベース手法，方策勾配法へと進む．最後に，標準的な設定だけでは捉えきれない発展的話題を概観する．

2.2.1　強化学習の歴史

強化学習の歴史を学ぶ必要があるのは，この分野が単に高性能な手法を寄せ集めて成立したのではなく，逐次意思決定に固有の困難に対する応答として発展してきたからである．信号制御，車両経路選択，需要応答交通の運行計画のような問題では，現在の行動が将来の混雑や待ち時間を変化させ，評価は複数時刻にまたがって現れる．したがって，入力と正解の対応をそのまま学べばよい教師あり学習とは異なり，行動の価値を試行錯誤から推定しなければならない．

このとき難しさの中心にあるのが，遅延報酬，探索と活用のトレードオフ，そして方策依存のデータ生成である．第一に，最終的な成果にどの行動が寄与したかを識別する信用割当ての問題が生じる．第二に，より良い行動を見つけるためには未知の選択肢を試す探索が必要だが，探索を増やせば当面の報酬は失われる．第三に，データは受動的に与えられるのではなく，学習者自身の行動によって生成される．これらの特徴が，強化学習に独自の理論を要請する．

歴史的源流は，Bellman による動的計画法と最適制御にある [**? ?**]．ここで与えられた基本原理は，長期最適化問題を現在の価値と将来の価値の再帰関係として表すベルマン方程式であった．ただし，この枠組みは環境モデル，すなわち状態遷移確率と報酬関数が既知であることを前提として

いた．理論的には明快であっても，未知環境から経験を通じて学ぶという強化学習本来の状況には，そのままでは適用できなかった．

この不足を埋めたのが時間差分学習（temporal-difference learning）である．**?**] は，将来の完全な帰結を待たず，次時刻の価値推定を足場にして現在の価値を更新するブートストラップの考え方を定式化した．これにより，モンテカルロ法のようにエピソード終了まで待たなくても逐次的に価値を学習できるようになった．ベルマン方程式は，解析のための式であるだけでなく，学習更新式の源泉になったのである．

さらに，**?**] による Q 学習は，行動価値関数を直接学ぶことで，環境モデルなしに最適方策へ近づく道を与えた．ここで重要なのは，価値推定と制御の問題が統合されたことである．TD 学習が与えられた方策の価値推定を中心にしていたのに対し，Q 学習は最大演算を通じて最適方策そのものを目指した．

状態空間が高次元化すると，表形式の価値関数では表現能力が不足する．この制約を緩和したのが深層強化学習であり，とくに DQN は画像入力から行動価値を学ぶ代表的成功例となった [**?**]．AlphaGo 以降は，価値学習，方策学習，探索，計画を組み合わせる深層強化学習が急速に発展した [**?**]．ただし，この発展は流行紹介として理解するべきではない．本質は，既知モデルから未知モデルへ，表形式から関数近似へ，価値推定から方策最適化へと理論の焦点が拡張された点にある．

同時に，価値ベース手法だけでは連続行動空間や確率的方策の直接最適化に限界があることも明らかになった．**?**] に始まる方策勾配法は，方策を直接最適化対象とする考え方を与え，後に Actor-Critic や PPO のような実用的手法へ発展した [**? ?**]．この歴史を貫いているのは，強化学習を「環境との相互作用のもとで累積報酬を最大化する確率的意思決定問題」としてどう定式化し，どう近似的に解くかという問いである．次節では，その標準的枠組みとしてマルコフ決定過程を導入する．

2.2.2　マルコフ決定過程

強化学習を厳密に論じるには，何が状態であり，何が行動であり，何が確率的に変化し，何を最大化したいのかを明示する必要がある．そのための標準的枠組みがマルコフ決定過程（Markov decision process; MDP）である．MDP によって，遅延報酬，価値関数，方策最適化という本章の主要概念を一つの数理的言語で記述できる．

().1　定義　MDP は，状態空間 $\mathcal{S}$，行動空間 $\mathcal{A}$，遷移確率 $P(s' \mid s, a)$，報酬関数 $r(s, a, s')$，割引率 γ からなる組

$$(\mathcal{S}, \mathcal{A}, P, r, \gamma)$$

として与えられる．ここで $s \in \mathcal{S}$ は現在状態，$a \in \mathcal{A}$ は現在行動，$s' \in \mathcal{S}$ は次状態を表す．遷移確率 $P(s' \mid s, a)$ は，状態 s で行動 a を選んだときに次状態が s' になる条件付き確率であり，報酬関数 $r(s, a, s')$ はその遷移に対応する即時報酬の期待値である．割引率 $\gamma \in [0, 1)$ は，将来報酬をどの程度現在価値として重視するかを表す係数である．

時刻 t に状態 s_t を観測し，行動 a_t を選び，報酬 r_t を受け取って次状態 s_{t+1} へ移るとする．このとき，時刻 t 以降の累積割引報酬，すなわちリターン G_t を

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

と定義する．添字 k は現在から何ステップ先の報酬かを表し，γ^k はその報酬に掛かる割引である．有限ホライズンではこの和は終端時刻までの有限和となり，無限ホライズンでは $\gamma < 1$ によって収束が保証される．

MDP の核心はマルコフ性にある．これは，次状態と次報酬の条件付き分布が，過去全体ではなく現在状態と現在行動だけで決まるという仮定であり，

$$\mathbb{P}(s_{t+1}, r_t \mid s_0, a_0, \ldots, s_t, a_t) = \mathbb{P}(s_{t+1}, r_t \mid s_t, a_t)$$

と書ける．この仮定が重要なのは，現在状態が将来予測に必要な情報を十分に要約しているとみなせるからである．その結果，長期最適化問題を再帰式として記述できる．

().2　定義　方策（policy）$\pi(a \mid s)$ は，状態 s のもとで行動 a を選ぶ条件付き確率である．決定論的方策では各状態に一つの行動が対応し，確率的方策では複数の行動に確率が割り当てられる．方策 π が与えられたとき，状態価値関数（state-value function）$V^\pi(s)$ と行動価値関数（action-value function）$Q^\pi(s,a)$ を

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid s_t = s],$$
$$Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]$$

と定義する．$\mathbb{E}_\pi[\cdot]$ は，方策 π と遷移確率 P のもとでの期待値である．$V^\pi(s)$ は状態 s にいることの長期的な良さを，$Q^\pi(s,a)$ は状態 s で行動 a を取ることの長期的な良さを表す．

これらの価値関数は，ベルマン期待方程式を満たす．状態価値関数については

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s,a,s') + \gamma V^\pi(s') \right]$$

が成り立つ．同様に，行動価値関数は

$$Q^\pi(s,a) = \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s,a,s') + \gamma \sum_{a' \in \mathcal{A}} \pi(a' \mid s') Q^\pi(s', a') \right]$$

を満たす．ここで $a' \in \mathcal{A}$ は次状態 s' における次の行動である．価値が即時報酬と将来価値の和として再帰的に分解されることが，強化学習の理論的出発点である．

最適方策 π^* は，全状態で価値を最大化する方策として定義される．対応する最適状態価値関数 $V^*(s)$ と最適行動価値関数 $Q^*(s,a)$ は

$$V^*(s) = \max_\pi V^\pi(s),$$
$$Q^*(s,a) = \max_\pi Q^\pi(s,a)$$

であり，ベルマン最適方程式

$$V^*(s) = \max_{a \in \mathcal{A}} \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s, a, s') + \gamma V^*(s') \right],$$

$$Q^*(s, a) = \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s, a, s') + \gamma \max_{a' \in \mathcal{A}} Q^*(s', a') \right]$$

を満たす．最大演算は，将来にわたって最も価値の高い行動を選ぶという最適制御の原理を表している．

有限ホライズンと無限ホライズン，エピソード型と継続型の区別も重要である．有限ホライズンでは終端時刻が存在し，無限ホライズンでは割引率が重要になる．エピソード型では終端状態に達すると課題が終了するのに対し，継続型ではタスクが終わらないため，交通流制御のような問題では長期的安定性をどう定義するかが論点になる．次節では，状態遷移という複雑さを一度外し，探索と活用の本質だけを切り出した多腕バンディット問題を考える．

2.2.3　多腕バンディット問題

MDP は強化学習の標準形であるが，状態遷移まで含めると探索と活用の本質が見えにくくなることがある．そこで，多腕バンディット問題（multi-armed bandit problem）を導入する．これは状態遷移を持たず，未知の行動価値を試行錯誤によって学ぶという構造だけを残した問題であり，強化学習の基礎概念を理解するうえで有用である [**? ?**].

().1　定義　K 本の腕を持つバンディットを考える．各腕 $i \in \{1, \ldots, K\}$ を選ぶと，未知分布に従う報酬が得られ，その期待値を μ_i とする．時刻 t に選ばれる腕を A_t，得られる報酬を r_t と書く．この問題には状態遷移がなく，意思決定は「次にどの腕を引くか」だけである．最適腕の期待報酬を $\mu^* = \max_i \mu_i$ とすると，目標は時刻 T までの累積期待報酬を最大化することである．

このとき，性能評価には後悔（regret）がよく用いられる．累積後悔 R_T を

$$R_T = T\mu^* - \mathbb{E}\left[\sum_{t=1}^{T} r_t \right]$$

と定義すると，これは「常に最適腕だけを引いた場合に比べてどれだけ損をしたか」を表す．強化学習全体では累積報酬最大化が中心目的であるが，バンディットでは後悔最小化の形で理論解析が明確になる．

最も単純な戦略の一つが ϵ-greedy である．これは確率 $1-\epsilon$ で現在までに推定された最良の腕を選び，確率 ϵ で一様ランダムに探索する方法である．ここで $\epsilon \in [0, 1]$ は探索率を表す．直感的には，既知の有望な腕を主に活用しつつ，未知の腕をときどき試すことで誤った早期収束を防ぐ．ただし，不確実性の大きさを腕ごとに使い分けないため，探索の効率は高くない．

これに対して，上側信頼限界法（upper confidence bound; UCB）は，推定平均と不確かさの両方を用いる [**? **]．腕 i の時刻 $t-1$ までの経験平均を $\hat{\mu}_i(t-1)$，その腕を選んだ回数を $N_i(t-1)$ とすると，典型的には

$$A_t = \arg\max_i \left[\hat{\mu}_i(t-1) + c\sqrt{\frac{\log t}{N_i(t-1)}} \right]$$

で腕を選ぶ．ここで $c > 0$ は探索の強さを調整する定数である．右辺第二項は未観測性に対応し，試行回数が少ない腕ほど大きくなる．したがって UCB は，「現在よさそうな腕」だけでなく「まだ十分試していないので本当は良いかもしれない腕」も積極的に選ぶ．

もう一つの代表的方法が Thompson sampling である [?]．これは，各腕の平均報酬に関する事後分布を持ち，そこから仮想的な平均報酬 $\tilde{\mu}_i$ をサンプルして

$$A_t = \arg\max_i \tilde{\mu}_i$$

とする方法である．たとえばベルヌーイ報酬では，成功確率にベータ分布を置くことで計算が容易になる．Thompson sampling の特徴は，探索が外的なランダム化としてではなく，パラメータ不確実性のベイズ的表現から自然に導かれる点にある．

バンディット問題が MDP より簡単なのは，状態遷移がないため，長期的な信用割当てを考える必要がないからである．一方で，本質的に共通している点も明確である．すなわち，未知の環境で累積報酬を最大化するには，不確実性のもとで探索と活用を両立させなければならない．この意味で，多腕バンディットは強化学習の縮約版である．次節では，再び状態遷移を導入し，ただし環境モデルが既知である場合の計画法として動的計画法を扱う．

2.2.4 動的計画法

動的計画法（dynamic programming）が必要になるのは，環境モデルが既知であれば，経験から学ぶ前に理論上の最適解を計算できるからである．これは現実にはしばしば非現実的な仮定であるが，強化学習アルゴリズムの基準点としてきわめて重要である．モデル未知の場合の TD 学習や Q 学習は，多くの場合この枠組みをサンプル近似したものと理解できる．

().1 定義　方策 π に対するベルマン作用素 T^π を

$$(T^\pi V)(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s, a, s') + \gamma V(s') \right]$$

と定義する．ここで V は任意の状態価値関数である．同様に，最適ベルマン作用素 T_* を

$$(T_* V)(s) = \max_{a \in \mathcal{A}} \sum_{s' \in \mathcal{S}} P(s' \mid s, a) \left[r(s, a, s') + \gamma V(s') \right]$$

と定義する．ベルマン期待方程式は $V^\pi = T^\pi V^\pi$，ベルマン最適方程式は $V^* = T_* V^*$ という不動点方程式になる．

().2 アルゴリズム　方策評価（policy evaluation）は，固定された方策 π の価値関数 V^π を求める手続きである．初期関数 V_0 を任意に取り，

$$V_{k+1} = T^\pi V_k$$

と反復すると，V_k は V^π に近づく．直感的には，価値は終端報酬や高報酬状態から逆向きに伝播する．まず 1 ステップ先の価値が更新され，その情報がさらに前の状態へ波及していくのである．

方策改善（policy improvement）は，現在の価値関数にもとづいてより良い行動を選ぶ段階である．すなわち，各状態 s について

$$\pi'(s) \in \arg\max_{a \in \mathcal{A}} \sum_{s' \in \mathcal{S}} P(s' \mid s, a)\,[r(s, a, s') + \gamma V^{\pi}(s')]$$

とすれば，新しい方策 π' は少なくとも π と同程度，通常はそれ以上の価値を持つ．これは，現在の価値評価に照らして各状態で最善の 1 ステップ行動を選べば，方策全体が改善することを意味している．

方策反復（policy iteration）は，方策評価と方策改善を交互に行う方法である．

1. 現在の方策 π_k を評価して V^{π_k} を求める．
2. V^{π_k} に対して貪欲化を行い，新しい方策 π_{k+1} を得る．
3. 方策が変化しなくなるまで反復する．

価値反復（value iteration）は，方策評価を完全に解かずに最適ベルマン作用素を直接適用する方法であり，

$$V_{k+1} = T_* V_k$$

を反復する．その後，各状態で価値を最大化する行動を選べば最適方策が得られる．価値反復は「いま分かっている将来価値に照らして最善の 1 ステップ選択」を毎回価値へ織り込む方法であり，計画と改善が一体化されている．

().3　定理　ベルマン作用素が収束をもたらす理由は，割引率 $\gamma < 1$ のもとで縮小写像になるからである．最大ノルム $\|V - W\|_\infty = \max_{s \in \mathcal{S}} |V(s) - W(s)|$ を用いると，

$$\|T^{\pi} V - T^{\pi} W\|_\infty \le \gamma \|V - W\|_\infty,$$
$$\|T_* V - T_* W\|_\infty \le \gamma \|V - W\|_\infty$$

が成り立つ．誤差が反復ごとに少なくとも γ 倍に縮むため，不動点に向かって収束する．直感的には，遠い将来の影響が割引によって弱まり，誤差が増幅しないことを意味する．

動的計画法は理論上の理想解法である一方，遷移確率と報酬関数が既知でなければ使えない．そのため，モデル未知の状況では期待値計算を実際の観測遷移で置き換える必要がある．次節では，その橋渡しとして TD 学習から Q 学習へ至る価値ベース手法を扱う．

2.2.5　価値ベース手法：Q 学習, Deep-Q 学習

現実の強化学習では，環境モデルが未知であることが多い．したがって，動的計画法のように遷移確率の期待値を厳密に計算することはできず，経験から価値を学習しなければならない．価値ベース手法は，価値関数を学ぶことを通じて最適方策を間接的に得る方法であり，モデル未知環境における強化学習の中心的流儀である．

出発点となるのは TD 学習である．状態価値関数 V に対する TD(0) の更新は

$$V(s_t) \leftarrow V(s_t) + \alpha\left[r_t + \gamma V(s_{t+1}) - V(s_t)\right]$$

で与えられる．ここで $\alpha \in (0,1]$ は学習率である．角括弧内の量

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

を TD 誤差という．δ_t は，現在の価値予測が 1 ステップ先の観測を踏まえてどれだけ過小または過大であったかを示す量であり，価値修正の方向と大きさを与える信号である．

制御問題では，状態そのものの価値だけでなく，各行動の価値を知る必要がある．そこで行動価値関数 $Q(s,a)$ を学習する．Q 学習は

$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha\left[r_t + \gamma \max_{a'} Q(s_{t+1},a') - Q(s_t,a_t)\right]$$

という更新式で定義される [**?**]．ここで $a' \in \mathcal{A}$ は次状態 s_{t+1} における候補行動であり，$\max_{a'} Q(s_{t+1},a')$ は将来に最善行動を選ぶと仮定した価値である．この最大演算を通じて，Q 学習は最適方策へ向かう．

Q 学習の重要な特徴は off-policy 学習である点にある．すなわち，実際にデータを収集する行動方策と，更新式の内部で想定している目標方策が一致していなくてもよい．たとえば ϵ-greedy によって探索を行いながら，更新時には貪欲方策を想定できる．これに対し SARSA は

$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha\left[r_t + \gamma Q(s_{t+1},a_{t+1}) - Q(s_t,a_t)\right]$$

と，実際に選ばれた次行動 a_{t+1} を用いて更新する on-policy 手法である．Q 学習が将来の最良行動に基づく強気の更新であるのに対し，SARSA は探索を含んだ現在の方策をそのまま評価する．

表形式の Q 学習は，状態空間と行動空間が小さいときには有効であるが，高次元状態では破綻する．画像入力や多数の交通状態特徴量のような状況では，各 (s,a) に対して表を持つことができない．このとき必要になるのが関数近似であり，Deep Q-Network（DQN）はニューラルネットワーク $Q(s,a;\theta)$ によって行動価値関数を近似する [**?**].

DQN では，TD ターゲットを

$$y_t = r_t + \gamma \max_{a'} Q(s_{t+1},a';\theta^-)$$

と置き，損失関数

$$L_t(\theta) = \left[y_t - Q(s_t,a_t;\theta)\right]^2$$

を最小化する．ここで θ は学習中のネットワークの重み，θ^- はターゲットネットワークの重みである．もし右辺のターゲットまで同じ重みで毎回更新すると，目標そのものが激しく動くため学習が不安定化する．ターゲットネットワークはこの問題を緩和し，更新先を一時的に固定する役割を果たす．

もう一つの重要要素が経験再生（experience replay）である．これは，過去の遷移 (s_t,a_t,r_t,s_{t+1}) をバッファに蓄積し，そこから無作為にミニバッチを抽出して学習する仕組みである．経験再生が必要なのは，連続する遷移が強く相関しているため，そのまま学習すると勾配推定が不安定になる

からである．無作為抽出により相関を弱められ，同じ経験を複数回再利用できるのでデータ効率も向上する．DQN の安定化は，この経験再生とターゲットネットワークに大きく依存している．

その後，Double DQN は最大演算に由来する過大評価を軽減し，dueling network は状態価値とアドバンテージを分離して表現することで学習効率を高めた．しかし中心的な論点は，TD 学習の再帰構造を深層関数近似とどう両立させるかにある．価値ベース手法の長所は，離散行動空間では各行動の価値を直接比較できること，ベルマン方程式との結びつきが明瞭であることである．一方で，連続行動空間では $\max_{a'} Q(s_{t+1}, a')$ の計算が難しく，確率的方策の直接制御や制約付き最適化にも不向きである．この限界が，次節で扱う方策勾配法の必要性を生む．

2.2.6　方策勾配法：Actor-Critic, PPO

価値ベース手法の限界が明確になるのは，連続行動空間や確率的方策の直接最適化を考えるときである．ロボット制御のように行動が実数ベクトルで表される場合，離散行動に対する最大化は自然ではない．また，探索を方策の分布そのものに埋め込みたい場合には，価値関数を介した間接的な最適化より，方策を直接最適化する方が適切である．この問題意識から方策勾配法が導入される．

パラメータ θ を持つ方策を $\pi_\theta(a \mid s)$ とし，期待リターンを

$$J(\theta) = \mathbb{E}_{\pi_\theta}[G_0]$$

と定義する．ここで $\mathbb{E}_{\pi_\theta}[\cdot]$ は，方策 π_θ と環境ダイナミクスに従って生成される軌道に関する期待値である．方策勾配法の目標は，$J(\theta)$ を最大化するように θ を更新することである．

().1　定理　方策勾配の基本形は

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t\right]$$

で与えられる [**?**]．ここで ∇_θ はパラメータ θ に関する勾配，$\log \pi_\theta(a_t \mid s_t)$ は選択された行動の対数確率，G_t は時刻 t 以降のリターンである．この式は，良い帰結をもたらした行動の確率を高め，悪い帰結をもたらした行動の確率を下げるという学習規則を正当化する．

REINFORCE はこの勾配を標本平均で近似する最も基本的なアルゴリズムであり，

$$\theta \leftarrow \theta + \alpha \sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t) G_t$$

と更新する．ここで α は学習率である．REINFORCE は不偏推定量を与えるが，G_t の分散が大きく，学習が不安定になりやすい．とくにホライズンが長い問題では，分散の削減が不可欠になる．

そこでベースライン $b(s_t)$ を導入し，

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\nabla_\theta \log \pi_\theta(a_t \mid s_t)\,(G_t - b(s_t))\right]$$

と書き換える．$b(s_t)$ が状態のみに依存する限り，勾配の期待値は変わらず，分散だけを減らせる．とくに $b(s_t) = V^\pi(s_t)$ と置くと，アドバンテージ関数

$$A^\pi(s_t, a_t) = Q^\pi(s_t, a_t) - V^\pi(s_t)$$

が現れる．これは，状態 s_t において行動 a_t が平均的行動よりどれだけ良かったかを表す量である．

Actor-Critic はこの考え方を実装する枠組みである．Actor は方策 $\pi_\theta(a \mid s)$ を表し，Critic は価値関数，典型的には $V(s;w)$ を推定する．ここで w は Critic のパラメータである．Critic は TD 学習により

$$\delta_t = r_t + \gamma V(s_{t+1};w) - V(s_t;w)$$

を計算する．この TD 誤差 δ_t は，1 ステップのアドバンテージ推定として機能する．したがって Actor は

$$\theta \leftarrow \theta + \alpha\, \delta_t\, \nabla_\theta \log \pi_\theta(a_t \mid s_t)$$

と更新できる．δ_t が正なら行動確率を増やし，負なら減らすので，Critic の価値推定が Actor の改善方向を与えることになる．

実際の深層強化学習では，方策更新が大きすぎると性能が急激に悪化することがある．TRPO は新旧方策の距離に制約を課すことでこの問題に対処したが [**?**]，計算は比較的重い．これに対し PPO は，同じ問題意識をより簡潔な目的関数で扱う [**?**].

PPO では，古い方策を $\pi_{\theta_{\mathrm{old}}}$，新しい方策を π_θ とし，確率比

$$r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)}$$

を考える．さらに A_t を推定アドバンテージとすると，clip された目的関数は

$$L^{\mathrm{clip}}(\theta) = \mathbb{E}\left[\min\left(r_t(\theta)A_t,\, \mathrm{clip}\left(r_t(\theta), 1-\epsilon, 1+\epsilon\right) A_t\right)\right]$$

と書かれる．ここで $\epsilon > 0$ は更新幅を制御するハイパーパラメータであり，$\mathrm{clip}(\cdot)$ は値を区間 $[1-\epsilon, 1+\epsilon]$ に切り詰める演算である．新方策が旧方策から過度に離れると，利得の増加が頭打ちになるため，大きすぎる更新が抑制される．

PPO が実用上の標準手法とみなされるのは，信頼領域の思想を保ちつつ，実装が容易でミニバッチ最適化とも相性がよいからである．とくに連続行動空間，大規模関数近似，確率的方策の直接制御が必要な問題では，方策勾配法の重要性は大きい．価値ベース手法が価値推定を通じて行動を導くのに対し，方策勾配法は望ましい行動分布そのものを直接整形する．この違いが，現代の深層強化学習における両者の役割分担を定めている．

2.2.7 発展的話題

標準的な MDP，価値学習，方策勾配法は強力な枠組みであるが，現実世界の課題をそのまま捉えられるわけではない．実応用では，環境モデルは未知であり，観測は不完全であり，安全制約があり，データ収集が高価であることが多い．この節では，そのような制約のもとで基本理論がどのように拡張されるかを概観する．

(a) モデルベース強化学習

モデルベース強化学習（model-based RL）が必要になるのは，サンプル効率を高めたいからである．モデルフリー手法は柔軟であるが，多数の試行を要する．実機ロボットや都市交通制御では，試行そのものが高価であり，環境モデルを全く使わない学習は非現実的であることが多い．

基本的な発想は，遷移モデル $\hat{P}$ と報酬モデル $\hat{r}$ をデータから学習し，その近似モデルの内部で計画やロールアウトを行うことである．モデルが十分正確なら，実環境での試行を減らしつつ方策改善ができる．一方で，モデル誤差は長期予測で蓄積しやすいため，短い計画区間に限定する，モデル不確実性を推定する，モデルフリー更新と併用するといった工夫が必要になる．

(b)　オフライン強化学習

オフライン強化学習（offline RL）が必要になるのは，新たな探索を現場で行えない状況があるからである．医療，金融，公共交通運用のような領域では，学習のために試しに危険な行動を取ることは許されない．そのため，過去に収集された固定データ集合

$$\mathcal{D} = \{(s, a, r, s')\}$$

だけを用いて方策を学習する．

ここでの難しさは，データに含まれていない行動を価値関数が過大評価しやすい点にある．すなわち，分布外の行動に対する楽観主義が性能劣化を招く．このため，オフライン強化学習では，行動方策に近い範囲で保守的に学習する，価値推定を意図的に低めに補正する，行動分布そのものを制約する，といった工夫が中心課題となる．

(c)　部分観測 **MDP**

標準的 MDP では現在状態が将来予測に必要な情報を十分含むと仮定したが，現実には状態そのものが直接観測できないことが多い．部分観測 MDP（partially observable MDP; POMDP）は，この状況を扱うための拡張であり，エージェントは状態 s_t の代わりに観測 o_t だけを得る．

このとき単一の観測だけでは意思決定に必要な情報が不足することがある．たとえば需要の潜在状態や他主体の意図は直接見えない．そこで，過去観測から信念状態を更新して隠れ状態の分布を内部状態として扱う方法や，再帰型ネットワークによって観測履歴を潜在表現へ圧縮する方法が用いられる．POMDP は，マルコフ性を放棄するのではなく，観測から実質的なマルコフ表現を再構成する問題として理解できる．

(d)　探索の高度化

疎な報酬や長いホライズンを持つ問題では，単純な ϵ-greedy では有益な経験に到達しにくい．このため，探索そのものを主題化する必要がある．代表的な考え方の一つが内発的動機づけ（intrinsic motivation）であり，新規性や予測誤差にもとづく探索ボーナスを外的報酬に加える．

たとえば修正報酬を

$$r'_t = r_t + \beta b_t$$

と書けば，$\beta > 0$ は探索ボーナスの重み，b_t は新規性や予測困難性を表す量である．ほかにも，不確実性の大きい行動を積極的に高く見る楽観主義や，事後分布から方策をサンプルする posterior sampling がある．探索は単なるランダム化ではなく，情報獲得をどう最適化するかという設計問題へ発展している．

(e)　多エージェント強化学習

多エージェント強化学習（multi-agent RL; MARL）が必要になるのは，環境が単一主体ではなく複数主体の相互作用で構成されるからである．交通流や配車市場では，各主体が学習することで他

主体にとっての環境も変化する．その結果，各エージェントから見れば環境は非定常となり，単一エージェント MDP の仮定がそのままでは通用しにくい．

ここでの問題は，協調と競争をどう扱うかである．協調型では局所情報から全体効率を高める共同方策を構成する必要があり，競争型では相手の学習を見越した戦略的適応が求められる．実用的には，学習時には全体情報を利用し，実行時には各主体が局所観測だけで動く centralized training with decentralized execution が広く用いられる．

(f) 模倣学習と逆強化学習

現実の問題では，報酬関数を適切に設計すること自体が難しい．自動運転や運行制御では，「安全」「快適」「効率」といった複数の目的を単一の数値報酬に落とし込むのが容易ではない．このとき，人間や既存システムの行動データを利用する方法として，模倣学習（imitation learning）と逆強化学習（inverse RL）が重要になる．

模倣学習は専門家の行動系列から直接方策を学ぶ方法であり，探索コストを大きく削減できる．逆強化学習は，専門家行動の背後にある報酬関数を推定し，その推定報酬のもとで方策最適化を行う方法である．前者が「どう行動するか」を学ぶのに対し，後者は「何を目的としているか」を推定する．いずれも，標準的な MDP ＋価値学習＋方策勾配だけでは扱いにくい現実的制約を補う拡張である．

2.2.8 まとめ

本章では，強化学習を環境との相互作用のもとで長期的な意思決定を最適化する理論として体系的に整理した．まず，教師あり学習や教師なし学習では十分に捉えられない遅延報酬，試行錯誤，探索と活用の問題から強化学習が必要になることを述べ，その歴史が動的計画法，TD 学習，Q 学習，深層関数近似，方策勾配法へと展開してきた流れを確認した．

続いて，マルコフ決定過程によって状態，行動，遷移確率，報酬，割引率，方策，価値関数を定義し，ベルマン方程式が強化学習全体の再帰的骨格であることを示した．多腕バンディット問題は，探索と活用の本質を状態遷移なしに抽出する縮約版として位置づけられ，動的計画法は環境モデル既知の場合の理論的基準点を与えた．そのうえで，モデル未知の状況では TD 学習と Q 学習が経験から価値を推定し，DQN が高次元状態へ拡張した．さらに，価値ベース手法の限界を受けて，方策勾配法，Actor-Critic，PPO が方策そのものを直接最適化する枠組みを与えることを見た．最後に，モデルベース強化学習，オフライン強化学習，POMDP，探索の高度化，多エージェント強化学習，模倣学習と逆強化学習を通じて，現実世界では未知性，部分観測，安全制約，データ収集制約が基本理論の拡張を要請することを確認した．以上を通じて，強化学習は「環境との相互作用のもとで価値関数または方策を学習し，長期的な意思決定を最適化する理論」として理解されるべきである．

参考文献

2.3　拡散モデルと生成モデル

本章では，生成モデルを，観測データの分布あるいは条件付き分布を学習し，そこから新しいサンプルを生成する確率モデルとして統一的に捉える。画像生成や文生成の成功は広く知られているが，重要なのは，生成モデルが単なる出力装置ではなく，潜在変数を通じた表現学習，尤度に基づく学習原理，近似推論，逐次生成，さらには予測と計画へ接続される一般的な枠組みであるという点にある。

本章の目標は三つある。第一に，潜在変数モデルの学習という観点から，EM アルゴリズムと変分オートエンコーダ（variational autoencoder; VAE）を位置づける。第二に，ノイズ除去過程としての拡散モデルを，離散時間から連続時間へと見通しよく整理する。第三に，自己回帰モデルと世界モデルを通じて，生成モデルが系列生成や意思決定支援へどのように拡張されるかを理解する。以下では，「潜在変数モデルの学習」「逐次生成」「ノイズ除去過程」という三つの視点が一貫して現れるように議論を進める。

2.3.1　生成モデルの考え方

この概念が必要になるのは，分類や回帰だけでは扱えない問いが多く存在するからである。たとえば欠損補完，異常検知，反実仮想的なシミュレーション，都市活動の需要分布の生成，交通軌跡の合成などでは，入力に対してラベルを当てるだけでなく，データそのものがどのような確率法則に従って生じるかを記述する必要がある。生成モデルは，この要請に対して，観測 x の分布を直接あるいは間接に学習する立場をとる。

(a)　分布を学ぶとは何か

識別モデル（discriminative model）は，典型的には入力 x からラベル y への条件付き分布 $p_\theta(y \mid x)$ を学習する。ここで θ は学習すべきパラメータである。これに対して生成モデル（generative model）は，観測データ x の分布 $p_\theta(x)$ を学ぶか，あるいは条件情報 c が与えられたときの条件付き分布 $p_\theta(x \mid c)$ を学ぶ。記号 $p_{\text{data}}(x)$ は真のデータ分布を表し，学習の目的は $p_\theta(x)$ を $p_{\text{data}}(x)$ に近づけることである。条件付き生成では，たとえば文脈 c に応じて文章や画像や将来軌跡を生成するために $p_\theta(x \mid c)$ を考える。

生成モデルを学ぶ最も自然な原理は最大尤度推定（maximum likelihood estimation）である。独立同分布に従う観測データ $x^{(1)}, \ldots, x^{(N)}$ が与えられたとき，尤度は

$$\prod_{n=1}^{N} p_\theta(x^{(n)})$$

であり，対数尤度は

$$\sum_{n=1}^{N} \log p_\theta(x^{(n)})$$

となる。ここで N は標本数である。対数をとると積が和に変わり，最適化や解析が行いやすくなる。したがって，生成モデルの中心課題は，対数尤度を大きくする θ を求めることだといえる。

しかし，この方針は概念的には自然であっても，計算の上では難しい。高次元データに対して $p_\theta(x)$ を直接評価すること自体が困難であり，とくに潜在変数を導入したモデルでは周辺化が障害となる。以下で見るように，EM アルゴリズム，VAE，拡散モデル，自己回帰モデルは，いずれもこの困難に対する異なる解法として理解できる。

(b)　潜在変数モデル

生成モデルで潜在変数（latent variable）z を導入する主な理由は，観測 x の背後にある低次元あるいは構造化された要因を分離し，表現学習を可能にするためである。潜在変数モデルの基本形は

$$p_\theta(x) = \int p_\theta(x \mid z)\, p(z)\, dz$$

で与えられる。ここで $p(z)$ は潜在変数 z の事前分布，$p_\theta(x \mid z)$ は z が与えられたときの観測 x の条件付き分布であり，しばしばデコーダとも呼ばれる。積分は，潜在変数 z を明示的には観測しないまま，その全ての可能性を足し合わせる周辺化を表す。z が離散変数なら積分は総和に置き換わる。

この式は，観測データの複雑な分布を，潜在空間での比較的単純な分布と条件付き生成機構の組合せとして表現することを意味する。たとえば顔画像なら，姿勢，照明，表情といった要因を z に担わせることが期待される。交通軌跡なら，目的地，出発時刻帯，混雑回避傾向などを潜在表現として持たせることができる。潜在変数は観測されないため，その推論が必要になるが，その代わりにデータ分布の説明力と表現の可搬性が得られる。

問題は，周辺尤度 $p_\theta(x)$ の計算が難しいことである。とくに $p_\theta(x \mid z)$ をニューラルネットワークで表すと，積分は解析的に解けないことが多い。また，学習中に必要な事後分布 $p_\theta(z \mid x)$ も容易には得られない。したがって，生成モデルにおける中心課題は，潜在変数を含む尤度最大化と近似推論をどのように両立させるかにある。

(c)　本章の見取り図

生成モデルには複数の流儀がある。敵対的生成ネットワーク（generative adversarial network; GAN）は識別器とのゲームを通じてサンプル品質を高める方法であり，自己回帰モデルは結合分布を条件付き分布の積に分解して逐次生成を行う。VAE は潜在変数モデルの学習を変分推論で実現し，拡散モデルはノイズ付加とノイズ除去の逐次過程として生成を定式化する。

本章では，まず潜在変数モデルを学習する古典的な方法として EM アルゴリズムを扱い，次に厳密事後分布が扱えない深層モデルへ進むために VAE を導入する。その後，ノイズ除去過程としての拡散モデルを離散時間と連続時間で整理し，最後に逐次生成の別系統として自己回帰モデルと

LLM を概観する。さらに，生成モデルが表現学習と予測を通じて環境理解へ拡張される例として世界モデルを取り上げる。これにより，生成モデルを，単なるサンプル生成ではなく，潜在表現の獲得と確率的予測の一般原理として捉えられるようになる。

2.3.2　EM アルゴリズム

この概念が必要になるのは，潜在変数を含むモデルでは，尤度最大化がしばしば直接には解けないからである。観測データだけを見れば単純な最適化問題に見えても，実際には観測されていない変数を周辺化した対数尤度が現れ，対数と積分が絡み合うために計算が難しくなる。EM アルゴリズム（expectation-maximization algorithm）は，この困難を「潜在変数の推定」と「パラメータの更新」に分けることで扱う。

(a)　完全データ尤度と不完全データ尤度

潜在変数を z，観測を x とすると，完全データ（complete data）は (x, z) であり，不完全データ（incomplete data）は x のみである。完全データの対数尤度

$$\log p(x, z \mid \theta)$$

は，モデルによっては扱いやすい。一方，不完全データの対数尤度は

$$\log p(x \mid \theta) = \log \int p(x, z \mid \theta)\, dz$$

であり，積分の外側に対数があるため，直接最適化しにくい。ここで θ はモデルパラメータであり，$p(x, z \mid \theta)$ は同時分布である。難しさの本質は，対数 log が線形ではないため，潜在変数の周辺化と素直に交換できないことにある。

この問題を緩和するために，任意の分布 $q(z)$ を導入して

$$\log p(x \mid \theta) = \log \int q(z) \frac{p(x, z \mid \theta)}{q(z)}\, dz$$

と書く。ここで $q(z)$ は潜在変数 z に関する補助的な分布であり，後で適切に選ぶ。対数関数は凹関数であるから，Jensen の不等式より

$$\log p(x \mid \theta) \geq \int q(z) \log \frac{p(x, z \mid \theta)}{q(z)}\, dz$$

が成り立つ。右辺は θ に関する下界であり，しばしば自由エネルギー（free energy）あるいは変分下界と呼ばれる。

(b)　**EM** の導出

上の下界を

$$\mathcal{F}(q, \theta) = \mathbb{E}_{q(z)}[\log p(x, z \mid \theta)] + H(q)$$

と書くことにする。ここで $\mathbb{E}_{q(z)}[\cdot]$ は分布 $q(z)$ に関する期待値であり，$H(q) = -\mathbb{E}_{q(z)}[\log q(z)]$ はエントロピーである。この量は

$$\log p(x \mid \theta) = \mathcal{F}(q, \theta) + \mathrm{KL}\big(q(z) \,\|\, p(z \mid x, \theta)\big)$$

と分解できる。右辺第二項の $\mathrm{KL}(\cdot\|\cdot)$ は Kullback–Leibler ダイバージェンスであり，二つの分布のずれを測る非負量である。したがって，$\mathcal{F}(q,\theta)$ は常に対数尤度の下界であり，しかも $q(z)=p(z\mid x,\theta)$ のときに下界は厳密に一致する。

EM アルゴリズムはこの事実を用いて，θ と q を交互に更新する。現在のパラメータを θ^{old} とすると，E-step では

$$q^{\mathrm{new}}(z)=p(z\mid x,\theta^{\mathrm{old}})$$

と置く。これにより，下界は現在のパラメータに対して最もきつくなる。続いて M-step では，この $q^{\mathrm{new}}(z)$ を固定して $\mathcal{F}(q^{\mathrm{new}},\theta)$ を θ について最大化する。エントロピー項 $H(q^{\mathrm{new}})$ は θ に依らないため，M-step は

$$Q(\theta\mid\theta^{\mathrm{old}})=\mathbb{E}_{p(z\mid x,\theta^{\mathrm{old}})}[\log p(x,z\mid\theta)]$$

を最大化する問題になる。ここで $Q(\theta\mid\theta^{\mathrm{old}})$ は補助関数（auxiliary function）であり，古いパラメータで計算した事後分布の下で完全データ対数尤度の期待値をとったものである。

以上をアルゴリズムとしてまとめると，EM は次の二段階を反復する。

1. E-step: 現在のパラメータ θ^{old} の下で事後分布 $p(z\mid x,\theta^{\mathrm{old}})$ を計算する。
2. M-step: 補助関数 $Q(\theta\mid\theta^{\mathrm{old}})$ を最大化して新しいパラメータ θ^{new} を得る。

この反復により，不完全データ対数尤度は単調非減少となる。EM が有効であるためには，E-step で厳密な事後分布を計算でき，M-step でも十分に扱いやすい最適化ができることが望ましい。

(c)　GMM における EM の直感

混合ガウスモデル（Gaussian mixture model; GMM）は EM の典型例である。K 個のクラスタを考え，観測 x_n がクラスタ k に属する確率を混合係数 π_k で表す。潜在変数 z_n はデータ点 x_n のクラスタ割当を表し，$z_n=k$ のとき

$$p(x_n\mid z_n=k,\theta)=\mathcal{N}(x_n;\mu_k,\Sigma_k)$$

とする。ここで μ_k はクラスタ k の平均，Σ_k は共分散行列である。

E-step では，各データ点が各クラスタに属する責務（responsibility）

$$\gamma_{nk}=p(z_n=k\mid x_n,\theta^{\mathrm{old}})=\frac{\pi_k\mathcal{N}(x_n;\mu_k,\Sigma_k)}{\sum_{j=1}^{K}\pi_j\mathcal{N}(x_n;\mu_j,\Sigma_j)}$$

を計算する。責務 γ_{nk} は，データ点 x_n がクラスタ k にどれだけ説明されるかを表す重みである。M-step では，この重み付き平均として

$$N_k=\sum_{n=1}^{N}\gamma_{nk},\quad \pi_k=\frac{N_k}{N},\quad \mu_k=\frac{1}{N_k}\sum_{n=1}^{N}\gamma_{nk}x_n$$

および

$$\Sigma_k=\frac{1}{N_k}\sum_{n=1}^{N}\gamma_{nk}(x_n-\mu_k)(x_n-\mu_k)^{\top}$$

を更新する。ここで N_k はクラスタ k に割り当てられた有効サンプル数である。

この例から分かるように，EM は「見えない割当を現在のモデルで推定し，その推定結果に基づいてモデルを更新する」反復である。したがって，EM は潜在変数モデルの最も基本的な学習原理の一つといえる。ただし，深層生成モデルでは事後分布 $p_\theta(z \mid x)$ を厳密に計算できないことが多い。その場合には，厳密事後分布を用いる EM の代わりに，近似事後分布を学習する変分推論が必要になる。次節では，この考え方をニューラルネットワークに組み込んだ VAE を扱う。

2.3.3 VAE

この概念が必要になるのは，深層潜在変数モデルでは真の事後分布 $p_\theta(z \mid x)$ がほとんどの場合に計算不可能だからである。EM は厳密な事後分布を扱えるときに強力だが，ニューラルネットワークを含む柔軟な生成モデルでは，E-step そのものが閉形式で書けない。VAE は，近似事後分布を別のパラメータで学習することにより，生成モデルの尤度最大化を実用的な最適化問題へ変換する。

(a) 変分推論と **ELBO**

VAE では，真の事後分布 $p_\theta(z \mid x)$ の代わりに，近似事後分布 $q_\phi(z \mid x)$ を導入する。ここで ϕ はエンコーダのパラメータであり，観測 x から潜在変数 z の分布を出力する。生成モデルは依然として

$$p_\theta(x, z) = p_\theta(x \mid z)p(z)$$

と書かれ，$p(z)$ は事前分布である。任意の $q_\phi(z \mid x)$ に対して，

$$\log p_\theta(x) = \mathbb{E}_{q_\phi(z|x)}\left[\log \frac{p_\theta(x, z)}{q_\phi(z \mid x)}\right] + \mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p_\theta(z \mid x)\big)$$

が成り立つ。右辺第二項は非負であるから，

$$\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] - \mathrm{KL}(q_\phi(z \mid x) \| p(z))$$

を得る。右辺がエビデンス下界（evidence lower bound; ELBO）である。ここで第一項は再構成項，第二項は KL 正則化項である。

再構成項

$$\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)]$$

は，潜在変数 z から元の観測 x をどれだけよく説明できるかを測る。これはオートエンコーダにおける復元誤差に相当するが，確率的な形で定式化されている。一方，KL 正則化項

$$\mathrm{KL}(q_\phi(z \mid x) \| p(z))$$

は，データごとの近似事後分布を共通の事前分布 $p(z)$ に近づける。これにより，潜在空間が無秩序に散らばることを防ぎ，サンプリング可能な構造を持たせる。VAE の学習は，この二つの要請，すなわち「よく再構成すること」と「潜在空間を整えること」の均衡である。

(b)　再パラメータ化トリックと学習

ELBO を確率的勾配法で最適化するには，$q_\phi(z \mid x)$ からサンプルした z を通じて ϕ に勾配を流す必要がある。しかし，単に「分布からサンプルする」と書くと，サンプリング操作が非微分的に見える。そこで再パラメータ化トリック（reparameterization trick）を用いる。

近似事後分布を平均 $\mu_\phi(x)$ と標準偏差 $\sigma_\phi(x)$ を持つ対角ガウス分布

$$q_\phi(z \mid x) = \mathcal{N}\big(z; \mu_\phi(x), \mathrm{diag}(\sigma_\phi(x)^2)\big)$$

とすると，潜在変数 z を

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

と書ける。ここで $\odot$ は要素ごとの積，I は単位行列，ϵ は標準正規分布からの補助ノイズである。重要なのは，確率性を ϵ に押し込み，$\mu_\phi(x)$ と $\sigma_\phi(x)$ については決定論的な変換として z を表した点にある。これにより，ϕ に関する勾配を，サンプル平均を通じて安定に推定できる。

事前分布を $p(z) = \mathcal{N}(0, I)$ とし，近似事後分布を上の対角ガウスとした場合，KL 項は解析的に計算できる。潜在次元を $j = 1, \ldots, d$ とすると，

$$\mathrm{KL}(q_\phi(z \mid x) \| p(z)) = \frac{1}{2} \sum_{j=1}^{d} \big(\mu_j(x)^2 + \sigma_j(x)^2 - \log \sigma_j(x)^2 - 1\big)$$

である。ここで $\mu_j(x)$ と $\sigma_j(x)$ は潜在変数の第 j 成分に対応する平均と標準偏差である。この閉形式は，VAE の実装を著しく簡潔にする。

(c)　表現学習としての **VAE** と限界

VAE の重要な意義は，生成と表現学習を同時に行う点にある。潜在空間が事前分布により正則化されるため，近い潜在ベクトルはしばしば意味的に近いサンプルを生成する。したがって，潜在空間上の補間は滑らかな変化として解釈されやすく，表現の連続性が得られる。これは，画像や軌跡や都市形状のような高次元データを低次元の意味表現へ圧縮する上で有用である。

他方で，VAE には典型的な限界もある。第一に，デコーダが強すぎると近似事後分布 $q_\phi(z \mid x)$ が事前分布 $p(z)$ に近づきすぎ，潜在変数がほとんど情報を持たなくなることがある。これは事後崩壊（posterior collapse）と呼ばれる。第二に，尤度を重視した平均化的な学習により，再構成や生成結果がぼけやすい。とくに多峰的な分布を単純なガウス尤度で近似すると，複数の可能性を平均したような出力になりやすい。

それでも VAE は，EM の考え方を深層モデルへ拡張した重要な橋渡しである。EM が厳密事後分布を用いるのに対し，VAE は近似事後分布 $q_\phi(z \mid x)$ 自体を学習する。この違いにより，潜在変数モデルの学習は大規模データと表現学習へ開かれた。次節では，潜在変数の推論ではなく，ノイズ除去の逐次過程として生成を定式化する拡散モデルを扱う。

2.3.4　拡散モデル

この概念が必要になるのは，高品質なサンプル生成と安定な学習を両立させる新しい生成原理が求められたからである。VAE は尤度と潜在表現を扱いやすい一方で出力がぼけやすく，GAN は

鋭いサンプルを生成できる一方で学習が不安定になりやすい。拡散モデル（diffusion model）は，データに徐々にノイズを加える前向き過程と，そのノイズを逆向きに除去する生成過程を組み合わせることで，尤度に根ざした学習と高品質生成を接続する。

(a)　前向き過程と閉形式

離散時間の拡散過程では，時刻 $t = 1, \ldots, T$ に対して，観測 x_{t-1} に小さなガウス雑音を加えて x_t を得る。前向き過程は

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I)$$

で定義される。ここで $\beta_t \in (0,1)$ は時刻 t のノイズ分散を表すスケジュールであり，I は単位行列である。β_t が小さいほど，1 ステップ当たりの変化は小さい。しばしば $\alpha_t = 1 - \beta_t$ とおく。

この前向き過程を繰り返すと，元のデータ x_0 は徐々に情報を失い，十分大きい T では標準正規分布に近い雑音 x_T へ到達する。重要なのは，累積係数

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$

を用いると，x_0 から任意の時刻 t の状態 x_t を 1 ステップで直接サンプルできることである。具体的には

$$q(x_t \mid x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}\, x_0, (1-\bar{\alpha}_t) I)$$

となり，したがって

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

と書ける。ここで ϵ は標準正規ノイズである。この閉形式は学習上きわめて重要であり，各時刻の中間状態 x_t を逐次シミュレーションせずに直接生成できる。

(b)　逆過程とノイズ予測

生成は前向き過程の逆，すなわち雑音 x_T から出発して徐々にノイズを除去し，最終的にデータ x_0 を得る過程として定式化される。逆過程のモデルを

$$p_\theta(x_{t-1} \mid x_t)$$

と書く。ここで θ はニューラルネットワークのパラメータであり，この条件付き分布が真の逆向き遷移を近似するように学習する。前向き過程の各ステップが十分小さいとき，逆向き条件付き分布も近似的にガウスになるため，平均や分散をネットワークで予測する設計が自然になる。

元来，拡散モデルは変分下界に基づいて導出されるが，実用上はノイズそのものを予測する学習目標に簡約されることが多い。すなわち，前向き過程で x_0 から x_t を生成する際に用いたノイズ ϵ を，ネットワーク $\epsilon_\theta(x_t, t)$ に予測させ，

$$\mathcal{L}_{\text{simple}} = \mathbb{E}\big[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\big]$$

を最小化する。ここで期待値は，データ x_0，時刻 t，およびノイズ ϵ に関する平均である。損失が平均二乗誤差になるのは，真のノイズを回帰問題として学習する立場をとっているからである。

この三者の関係を明確にしておこう。前向き過程 $q(x_t \mid x_{t-1})$ はデータを徐々に壊す既知の確率過程であり，逆過程 $p_\theta(x_{t-1} \mid x_t)$ は壊れたデータから元の構造を回復する学習対象である。そしてノイズ予測 $\epsilon_\theta(x_t, t)$ は，逆過程を実装するための実用的なパラメータ化である。すなわち，ネットワークが「いま見えている x_t の中にどれだけノイズが混ざっているか」を推定できれば，そこから一段前の状態 x_{t-1} を構成できる。

(c)　条件付き生成と位置づけ

条件付き生成では，条件 c を入力に加えて $\epsilon_\theta(x_t, t, c)$ を学習し，$p_\theta(x \mid c)$ に相当する生成を行う。画像生成ならテキスト条件，交通分野なら出発地，目的地，時刻帯，天候などを条件とできる。さらに，分類器なしガイダンス（classifier-free guidance）は，条件付き予測と無条件予測を組み合わせて条件への忠実度を調整する手法であり，生成品質と条件整合性の実用的な制御を可能にする。

拡散モデルの要点は，生成を一挙に行うのではなく，容易に記述できる破壊過程と，それを反転する学習可能な回復過程へ分解したことにある。この見方をさらに推し進めると，時間刻みを無限に細かくした連続時間の確率過程へ到達する。次節では，その連続時間化がどのように理論を統一するかを見る。

2.3.5　連続時間拡散モデル

この概念が必要になるのは，離散時間の拡散モデルをより一般的な確率過程として理解すると，理論とアルゴリズムの見通しが大きく改善するからである。離散時間のデノイジング拡散確率モデル（denoising diffusion probabilistic model; DDPM）では時刻 $t = 1, \ldots, T$ の格子上でノイズを加えていたが，刻み幅を十分小さくすると，連続時間の確率微分方程式で前向き過程と逆過程を統一的に表現できる。

(a)　前向き **SDE** と逆時間 **SDE**

連続時間では，時刻を $t \in [0, T]$ とし，データ分布から出発する確率過程 x_t を確率微分方程式（stochastic differential equation; SDE）

$$dx = f(x, t)\, dt + g(t)\, dw$$

で表すことが多い。ここで $f(x, t)$ はドリフト項，$g(t)$ は拡散係数，w は標準 Wiener 過程である。ドリフト項は決定論的な流れを，拡散項はランダムなノイズ注入を表す。前向き SDE（forward SDE）は，時刻とともに分布を単純化し，最終的に扱いやすい既知分布へ近づける過程に対応する。

このとき，各時刻における周辺分布を $p_t(x)$ と書く。$p_t(x)$ は時刻 t での x_t の確率密度であり，初期時刻 $t = 0$ ではデータ分布，終端時刻 $t = T$ ではほぼガウス雑音になるように設計される。Song らが示した重要な結果によれば，適切な正則性の下で，時間を逆向きにたどる逆時間 SDE（reverse-time SDE）は

$$dx = \left[f(x, t) - g(t)^2 \nabla_x \log p_t(x) \right] dt + g(t)\, d\bar{w}$$

と書ける。ここで $\nabla_x \log p_t(x)$ は時刻 t の分布の対数密度勾配であり，スコア関数（score function）と呼ばれる。また，$\bar{w}$ は逆向き時間に対応する Wiener 過程である。つまり，逆過程を記述する鍵は，各時刻の密度そのものではなく，その勾配である。

(b) スコア関数とスコアベース生成

スコア関数

$$\nabla_x \log p_t(x)$$

は，空間の各点で「密度がどちらの方向に増えるか」を示すベクトル場である。スコアベース生成モデル（score-based generative modeling）は，密度 $p_t(x)$ を明示的にモデル化する代わりに，このスコア関数をニューラルネットワーク $s_\theta(x,t)$ で近似する立場をとる。密度そのものを正規化定数まで含めて求めるのは難しいが，対数密度勾配は学習しやすい場合があり，しかも逆時間 SDE の構成にはそれで十分である。

スコアマッチング（score matching）は，この勾配場を直接学習する枠組みである。とくにノイズを加えたデータに対するデノイジング・スコアマッチングでは，ノイズレベルごとのスコアを学習し，それを用いて逆向きにサンプリングする。離散時間の拡散モデルでノイズ ϵ を予測する手法は，連続時間のスコア推定と密接に対応している。実際，ガウス摂動の下ではノイズ予測とスコア推定は定数倍の違いを除いて等価になる。

(c) 離散時間との対応と統一的理解

連続時間化の意義は，離散時間モデルと別物の理論を導入することではなく，それらを一つの枠組みへ包摂することにある。離散時間の DDPM で用いた β_t スケジュールは，連続時間では拡散係数 $g(t)$ に対応し，逆過程の平均推定はスコア関数によるドリフト補正として理解できる。したがって，DDPM は連続時間 SDE の時間離散化の一つとみなせる。

さらに，reverse-time SDE と同じ周辺分布を持つ常微分方程式

$$\frac{dx}{dt} = f(x,t) - \frac{1}{2}g(t)^2 \nabla_x \log p_t(x)$$

を考えることもでき，これは確率流常微分方程式（probability flow ODE）と呼ばれる。ここで常微分方程式はノイズ項を持たない決定論的な流れであり，尤度計算や高速サンプリングの解析に有用である。もっとも，本質は，連続時間化によって「ノイズ付加」「スコア推定」「逆過程サンプリング」が統一的に記述できるようになった点にある。

ここまでの拡散モデルは，ノイズ除去に基づく逐次生成であった。これに対して，系列の自然な順序に従って条件付き分布を直接学習する立場も存在する。次節では，言語モデルを代表例とする自己回帰生成を扱う。

2.3.6 自己回帰モデルと LLM

この概念が必要になるのは，系列データにはしばしば自然な因果順序があり，その順序に沿って結合分布を厳密に分解できるからである。文，音声，行動列，交通需要の時系列は，先行する要素が後続の要素に情報を与える。こうした場合には，潜在変数を積分消去するよりも，条件付き分布そのものを逐次的に直接学習する方が自然である。

(a) 連鎖律による生成

自己回帰モデル（autoregressive model）は，長さ T の系列 $x_1, \ldots, x_T$ の結合分布を確率の連鎖律により

$$p(x_1, \ldots, x_T) = \prod_{t=1}^{T} p(x_t \mid x_{<t})$$

と分解する。ここで $x_{<t}$ は時刻 t より前の要素 $x_1, \ldots, x_{t-1}$ をまとめて表す。左辺の結合分布を直接扱う代わりに，各時刻の条件付き分布を学べばよいという点がこの枠組みの核心である。

学習は通常，教師ありの次トークン予測（next-token prediction）として行われる。すなわち，系列全体の対数尤度

$$\log p(x_{1:T}) = \sum_{t=1}^{T} \log p(x_t \mid x_{<t})$$

を最大化する。ここで $x_{1:T}$ は系列全体を表す略記である。自己回帰モデルでは，各条件付き分布が明示的に規格化されているため，尤度計算が比較的直接的である。その代わり，生成時には x_1 から順に 1 トークンずつサンプルしなければならず，本質的に逐次的である。

(b)　n-gram から Transformer へ

自己回帰言語モデルの古典的な形は n-gram であり，現在の単語の確率を直前 $n-1$ 個の単語に条件づけて推定する。これは有限長文脈しか見られないという制約を持つが，連鎖律に基づく生成という発想自体はすでに備えている。次に再帰型ニューラルネットワーク（recurrent neural network; RNN）による言語モデルが現れ，隠れ状態に過去の情報を圧縮することで可変長文脈を扱えるようになった。

さらに，Transformer は自己注意機構により，系列内の離れた位置同士の依存関係を効率的に表現できるようにした。マスク付き自己注意を用いれば，将来のトークンを見ずに $p(x_t \mid x_{<t})$ を学習できる。大規模言語モデル（large language model; LLM）は，この自己回帰 Transformer を大規模データと大規模計算資源で学習したものであり，本質的には巨大な条件付き分布推定器である。

LLM において，入力は通常，単語そのものではなく離散トークン列へ変換される。モデルはトークン埋め込みと位置情報を用いて文脈を表現し，次トークンの条件付き分布を出力する。パラメータ数とデータ量と計算量を増やすと性能が系統的に向上するというスケーリング則は，自己回帰モデルが高い表現力を持つことを示している。また，文脈内に与えられた例から振る舞いを調整するインコンテキスト学習（in-context learning）は，明示的なパラメータ更新なしに条件付き分布を柔軟に活用している現象として理解できる。

(c)　拡散モデルとの対比

自己回帰モデルと拡散モデルは，どちらも逐次生成を行うが，その逐次性の意味が異なる。自己回帰モデルでは，順方向の因果分解に基づいて $x_1, x_2, \ldots$ を一つずつ生成する。これに対して拡散モデルでは，ノイズの多い状態からノイズの少ない状態へと反復的に洗練する。前者は条件付き分布 $p(x_t \mid x_{<t})$ を直接学ぶ枠組みであり，後者は逆過程 $p_\theta(x_{t-1} \mid x_t)$ を学ぶ枠組みである。

この違いは，潜在変数や近似推論との関係にも表れる。自己回帰モデルは，潜在変数を明示せずに高次元分布を分解して扱う。一方，VAE や世界モデルでは潜在表現が前面に現れ，拡散モデルではノイズ状態という補助変数が逐次的に導入される。どの立場をとるかは，対象データの構造，必要とされる尤度計算，生成速度，条件付けの仕方に依存する。次節では，生成モデルがさらに一歩進み，環境の内部遷移そのものを学習する世界モデルへ向かう。

2.3.7 世界モデル

この概念が必要になるのは，生成モデルの役割が単なるサンプル生成にとどまらず，予測，計画，制御へ広がるからである。エージェントが環境中で行動するとき，本当に必要なのは「もっともらしい画像を生成すること」だけではない。観測の背後にある状態を圧縮して表現し，行動に応じて将来がどう変化するかを内部でシミュレーションできることが重要である。世界モデル（world model）は，この内部シミュレータを生成モデルとして構成する。

(a) 潜在動的モデルの基本形

時刻 t における観測を o_t，潜在状態を z_t，行動を a_t とする。世界モデルの基本構図は，観測列の背後に低次元の潜在状態列を仮定し，その時間発展を学習することである。典型的には

$$p(z_1)\,p(o_1 \mid z_1)\prod_{t=2}^{T} p(z_t \mid z_{t-1}, a_{t-1})\,p(o_t \mid z_t)$$

という形の潜在動的モデルを考える。ここで $p(z_t \mid z_{t-1}, a_{t-1})$ は遷移モデル，$p(o_t \mid z_t)$ は観測モデルである。遷移モデルは行動 a_{t-1} を受けて潜在状態がどう変わるかを記述し，観測モデルは潜在状態からセンサ入力や画像や計測値がどう生成されるかを表す。

この構図は，VAE の潜在変数モデルを時間方向へ拡張したものと見なせる。観測 o_t をそのまま次時刻へ渡すのではなく，まず圧縮された潜在表現 z_t を介して扱うことで，高次元観測の冗長性を除きつつ，力学的に意味のある状態遷移を学習できる。表現学習と動的予測が結合している点が世界モデルの本質である。

(b) **RSSM** と想像上ロールアウト

実際のモデルでは，確率的な潜在状態だけでなく，決定論的な再帰状態を併用することが多い。たとえば再帰状態空間モデル（recurrent state-space model; RSSM）は，確率的潜在変数と RNN 的な隠れ状態を組み合わせ，部分観測環境でも十分な履歴情報を保持できるようにする。この種のモデルは潜在力学モデル（latent dynamics model）と総称され，モデルベース強化学習（model-based reinforcement learning）において重要な役割を果たしている。

学習された遷移モデルがあれば，実環境で行動せずとも，潜在空間内で将来軌跡を展開できる。これが想像上ロールアウト（imagined rollout）である。具体的には，現在の潜在状態推定 z_t から，候補行動列 $a_t, a_{t+1}, \ldots$ を仮定して

$$z_{t+1}, z_{t+2}, \ldots$$

を遷移モデルで生成し，必要なら観測や報酬もデコードする。これにより，エージェントは現実世界で高価な試行錯誤を行う前に，内部モデル上で計画や方策評価を行える。交通シミュレーションでいえば，仮想的な需要変動や信号制御の変更が将来流動へ与える影響を，学習済み潜在力学上で検討することに相当する。

(c) 生成モデルから意思決定支援へ

世界モデルは，生成モデルの役割を三方向へ拡張する。第一に，観測の生成という意味で，依然として確率的なデコーダを持つ。第二に，潜在状態の学習という意味で，表現学習の装置でもある。第三に，行動条件付きの将来予測を通じて，計画と意思決定を支援する。ここでは生成が，見

た目のサンプル合成ではなく，「もしこの行動をとったら何が起こるか」を内的に予測する能力へ転化している。

したがって，世界モデルは，本章で見てきた諸概念の自然な統合点である。潜在変数，近似推論，逐次生成，条件付き分布，表現学習がすべて現れるからである。生成モデルは，データ分布を学ぶ技術から出発しながら，最終的には環境の理解と行動選択を支える内部表現へと発展する。本章の締めくくりとして，この拡張可能性を意識しておくことが重要である。

まとめ

本章では，生成モデルを，データ分布の学習という統一的な視点から整理した。まず，識別モデルとの対比を通じて，生成モデルが $p_\theta(x)$ や $p_\theta(x \mid c)$ を学び，新しいサンプルを生成するだけでなく，欠損補完や異常検知や合成データ生成に資する確率モデルであることを確認した。その上で，潜在変数モデル

$$p_\theta(x) = \int p_\theta(x \mid z)\, p(z)\, dz$$

を導入し，複雑な観測分布を背後の表現と生成機構へ分解することの意味を見た。

続いて，潜在変数を含む尤度最大化の困難に対して，EM アルゴリズムが厳密事後分布を用いて下界最大化を行う方法であることを示し，さらに VAE が近似事後分布 $q_\phi(z \mid x)$ を学習することで，深層潜在変数モデルへこの考え方を拡張することを見た。ここでは，尤度，近似推論，表現学習が密接に結びついている。次に，拡散モデルでは，生成がノイズ除去の逐次過程として再定式化され，離散時間の DDPM から連続時間の SDE とスコア関数へ至る統一的理解が得られた。さらに，自己回帰モデルでは，結合分布の因果分解に基づいて条件付き分布を逐次的に直接学習する立場を確認し，LLM がその大規模な実例であることを位置づけた。最後に，世界モデルを通じて，生成モデルが観測生成だけでなく，将来予測，想像上ロールアウト，計画へ拡張されることを見た。

以上を通じて，生成モデルは，データ分布の学習，潜在表現の獲得，逐次的・確率的生成，さらには予測と計画へ拡張される統一的枠組みとして理解できる。個々の手法は，潜在変数をどう導入するか，尤度や下界をどう最適化するか，生成をどの方向の逐次過程として捉えるかという点で異なるが，いずれも「データがどのように生じるか」を数理的に記述しようとする試みである。

参考文献

参考文献

[1] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.

[2] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012.

[3] A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum Likelihood from Incomplete Data via the EM Algorithm," *Journal of the Royal Statistical Society: Series B*, Vol. 39, No. 1, pp. 1–38, 1977.

[4] D. P. Kingma and M. Welling, "Auto-Encoding Variational Bayes," in *Proceedings of the 2nd International Conference on Learning Representations*, 2014.

[5] D. J. Rezende, S. Mohamed, and D. Wierstra, "Stochastic Backpropagation and Approximate Inference in Deep Generative Models," in *Proceedings of the 31st International Conference on Machine Learning*, pp. 1278–1286, 2014.

[6] J. Sohl-Dickstein, E. A. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep Unsupervised Learning using Nonequilibrium Thermodynamics," in *Proceedings of the 32nd International Conference on Machine Learning*, pp. 2256–2265, 2015.

[7] J. Ho, A. Jain, and P. Abbeel, "Denoising Diffusion Probabilistic Models," in *Advances in Neural Information Processing Systems 33*, pp. 6840–6851, 2020.

[8] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, "Score-Based Generative Modeling through Stochastic Differential Equations," in *Proceedings of the 9th International Conference on Learning Representations*, 2021.

[9] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention Is All You Need," in *Advances in Neural Information Processing Systems 30*, pp. 5998–6008, 2017.

[10] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, "Language Models are Few-Shot Learners," in *Advances in Neural Information Processing Systems 33*, pp. 1877–1901, 2020.

[11] D. Ha and J. Schmidhuber, "World Models," *arXiv preprint arXiv:1803.10122*, 2018.

[12] D. Hafner, T. Lillicrap, J. Ba, and M. Norouzi, "Learning Latent Dynamics for Planning from Pixels," in *Proceedings of the 36th International Conference on Machine Learning*, pp. 2555–2565, 2019.

[13] D. Hafner, T. Lillicrap, M. Norouzi, and J. Ba, "Dream to Control: Learning Behaviors by Latent Imagination," in *Proceedings of the 8th International Conference on Learning Representations*, 2020.